PROJET 6

AMÉLIOREZ LE PRODUIT IA DE VOTRE START-UP

- EN DÉTECTANT LES SUJETS D'INSATISFACTION DANS DES COMMENTAIRES
- EN LABELISANT AUTOMATIQUEMENT DES PHOTOS POSTÉES

#NLP #LDA #LSA #TSNE #COMPUTER VISION #TRANSFER LEARNING #VGG16
#NLTK #WORDCLOUD #GENSIM #OPENCV #KERAS
#GRAPHQL

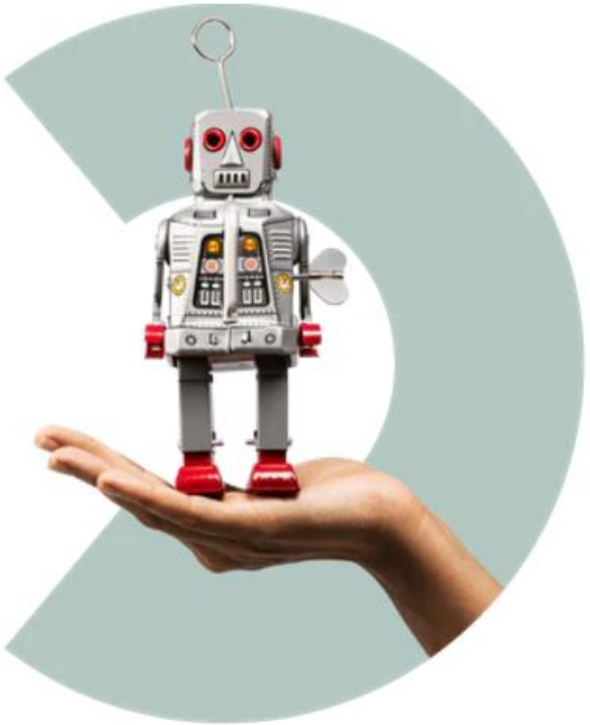

Ingénieur IA

Développez et intégrez des algorithmes de Deep Learning au sein d'un produit IA

OPENCLASSROOMS

OUDDANE NABIL

SOMMAIRE

Projet 6

A INTRODUCTION

1. Contexte

- ENJEU global:
  - améliorer la plateforme avec une **nouvelle fonctionnalité de collaboration**
  - Détecter les **sujets d'insatisfaction** présents dans les commentaires postés sur la plateforme.
  - **Labelliser automatiquement les photos** postées sur la plateforme

- ENJEU Compétences DU P5:
  - NLP / Computer Vison / API YELP

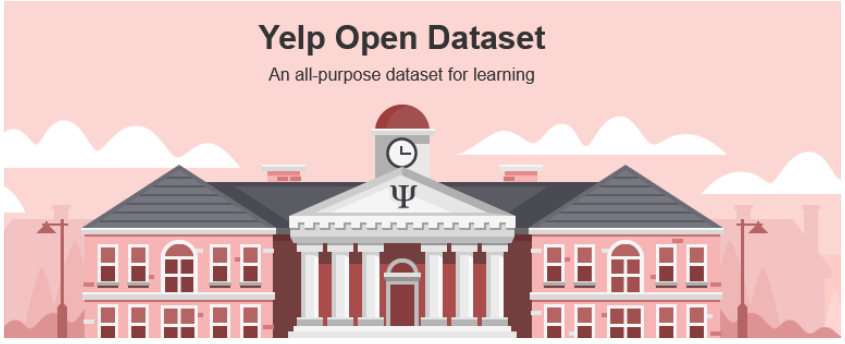

- DONNEES SOURCES
  - le jeu de données :
    - https://www.yelp.com/dataset

2. Objectifs

- SCRIPT:
  - analyser les commentaires pour **détecter les différents sujets d'insatisfaction**
  - analyser les photos pour **déterminer les catégories des photos**
  - **collecter un échantillon** (environ 200 restaurants) de données via l'API Yelp
- SOUTENANCE :
  - Délivrer cette présentation
  - Délivrer un script python jupyter autoporteur

3. Ressources complémentaires

- Chargement de gros volumes de données:
  - https://www.codementor.io/guidotournois/4-strategies-to-deal-with-large-datasets-using-pandas-qdw3an95k
- TEXTE
  - Python NLP: https://www.youtube.com/watch?v=SCs8N_-t3cE
  - Preprocessig de texte: https://datascientest.com/introduction-au-nlp-natural-language-processing
  - Preprocessig de texte & classification: https://www.actuia.com/contribution/victorbigand/tutoriel-tal-pour-les-debutants-classification-de-texte/
  - NLP: https://towardsdatascience.com/natural-language-processing-nlp-for-machine-learning-d44498845d5b
  - NLTK: https://www.nltk.org/
  - NLTK: https://code.tutsplus.com/fr/tutorials/introducing-the-natural-language-toolkit-nltk--cms-28620
  - Cours: https://openclassrooms.com/fr/courses/6532301-introduction-to-natural-language-processing
  - Cours: https://nlp-ensae.github.io/
  - https://scikit-learn.org/stable/modules/generated/sklearn.metrics.adjusted_rand_score.html

- Computer Vizualisation
  - Detecter la meteo: https://app.livestorm.co/openclassrooms-1/pretraitement-dimages-detecter-automatiquement-la-meteo?type=detailed
  - https://s3-eu-west-1.amazonaws.com/course.oc-static.com/projects/Webinars/Data/AI_Avril_2021/Weather_first_analysis_V1.0.ipynb
  - Transfer Learning: https://machinelearningmastery.com/how-to-use-transfer-learning-when-developing-convolutional-neural-network-models/
  - https://docs.microsoft.com/fr-fr/learn/modules/introduction-to-deep-learning/

B

PROJET NLP/LDA: ANALYSEZ LES COMMENTAIRES POUR DÉTECTER LES DIFFÉRENTS SUJETS D'INSATISFACTION

Analyse rapide des fichiers YELP

DownLoad de l'archive yelp tgz:
https://www.yelp.com/dataset
puis décompression

↓

Lecture des 5 fichiers json
Création de fonction speciale gérant la lourdeur des fichiers en lecture

↓

Selection des restaurants qui ont plus de 700 reviews
(1000 restaurants/ 1 millions de reviews)

↓

Puis filtrage des reviews en anglais grace à la detection du modèle pré entrainé fastext

↓

Enregistrement en bin grace à feather

Infos principales:
On a globalement plus de bonnes reviews que de mauvaises

→

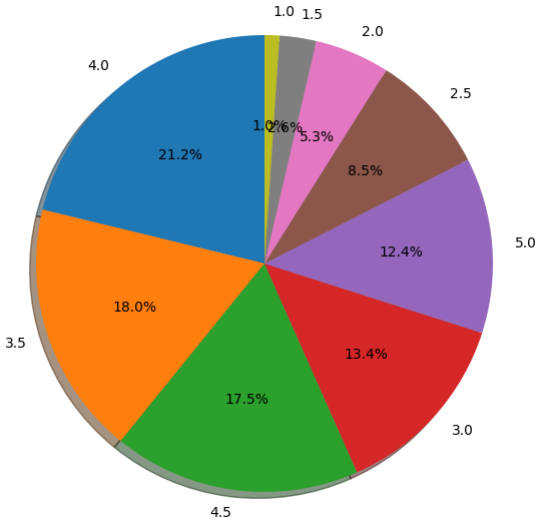

Pourquoi Feather?

https://towardsdatascience.com/the-best-format-to-save-pandas-data-414dca023e0d

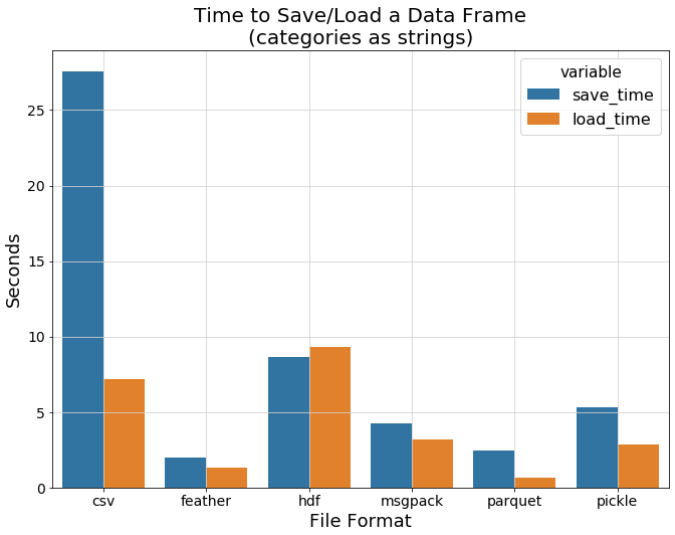

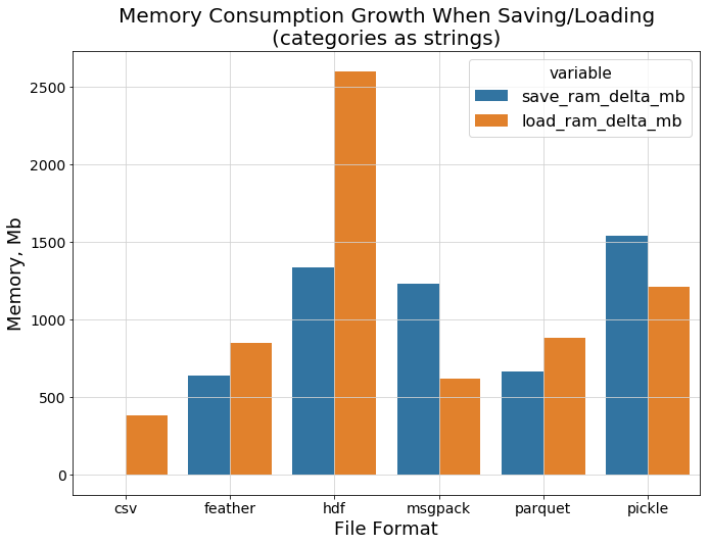

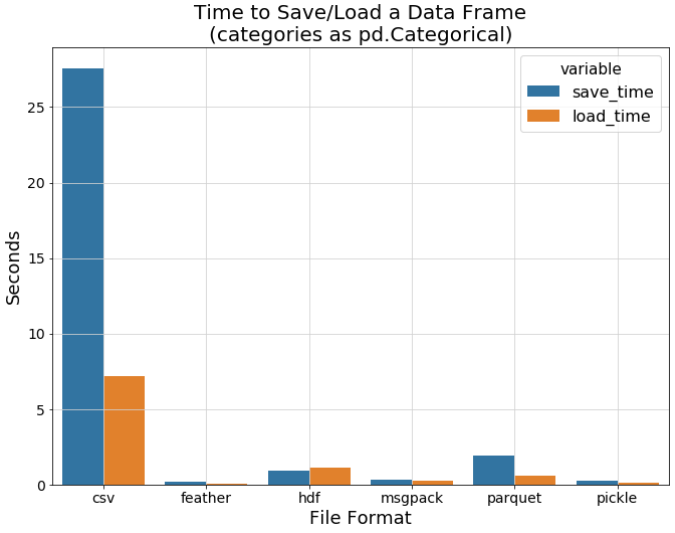

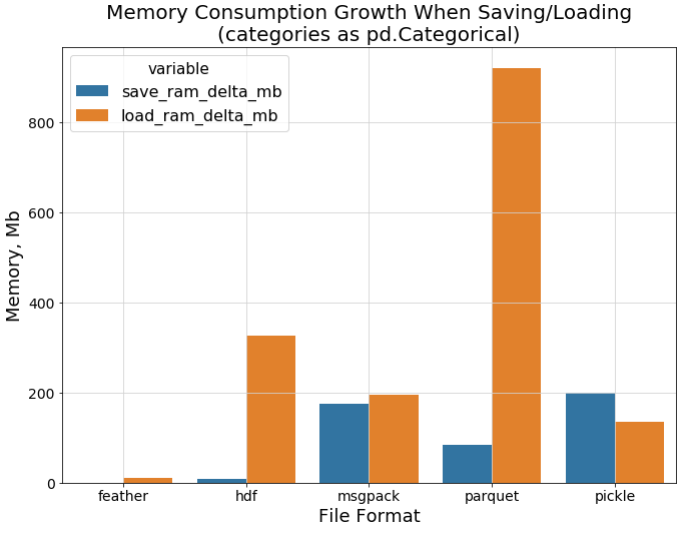

Reviews PreProcessing

- Suppression des textes entre crochets
- Suppression des liens internet
- Suppression des textes entre chevrons
- Suppression des retours à la ligne
- Suppression de la ponctuation
- Mise en minuscule

Tokenisation

Suppression des stopwords:
Stopwords de la liste nltk.corpus.stopwords('english') et enrichie des mots suivants:
['us', 'im', 'c', "youre", "youve", "youll", "youd", "thatll", "shouldve", "arent", "couldnt", "didnt","doesnt","dont", "hadnt", "hasnt", "havent", "isnt", "mightnt", "mustnt", "neednt", "shant", "shouldnt", "wasnt", "werent", "wont", "wouldnt"]

Lemmatization avec le WordNetLemmatizer de NLTK.stemm

Suppression des mots n'appartenant pas au dictionnaire nltk.corpus.words()

Stemming avec le nltk.stem.snowball

La lemmatization possède l'avantage de garder un mot correct.

Ce n'est pas toujours le cas du stemming dont les algorithmes sont plus ou moins aggressifs

(exemple par ordre croissants d'aggressivité:
nltk.stem.porter
nltk.stem.snowball
nltk.stem.Lancaster)

Problème dans le cas de l'utilisation d'un dictionnaire ou d'un modèle pré entrainé

Visualisation Wordcloud des mots les plus courants pour les mauvaises notes

Après lemmatization

Après lemmatization puis stemming

Vectorisation : Bag of words
fonction CountVectorizer de sklearn.feature_extraction.text

max_features 100 words/bigrams

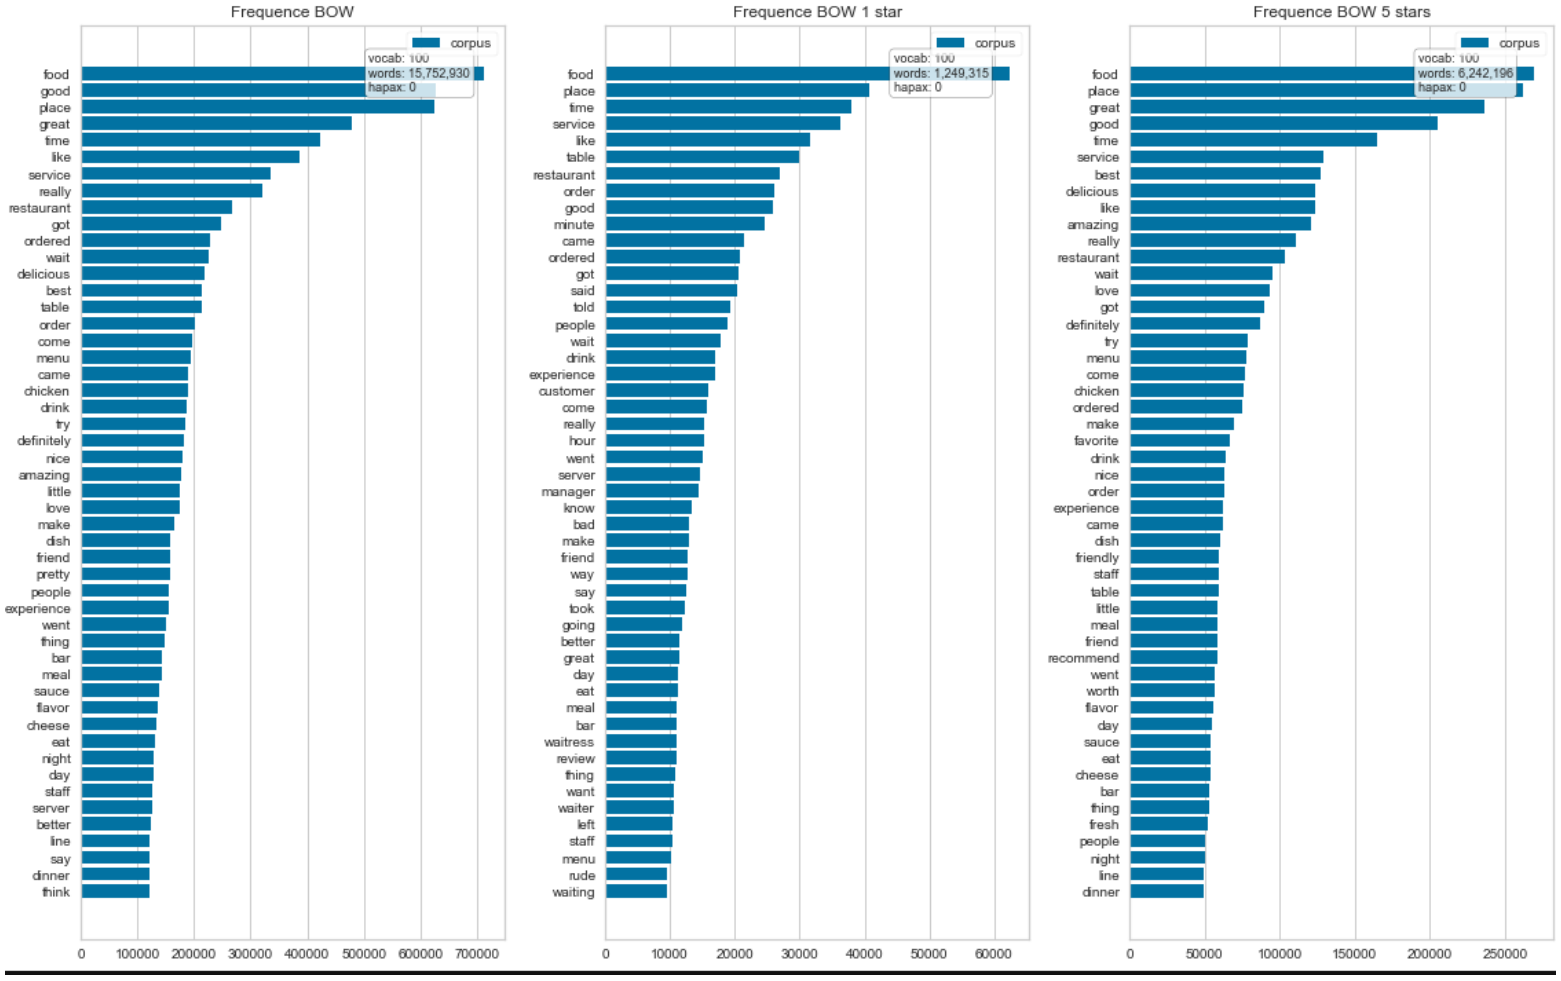

Vectorisation : Bag of words avec l'option binaire fonction CountVectorizer de sklearn.feature_extraction.text

max_features 100 words/bigrams : l'option binaire (presence ou non du mot dans le document sans comptage multiple par document)

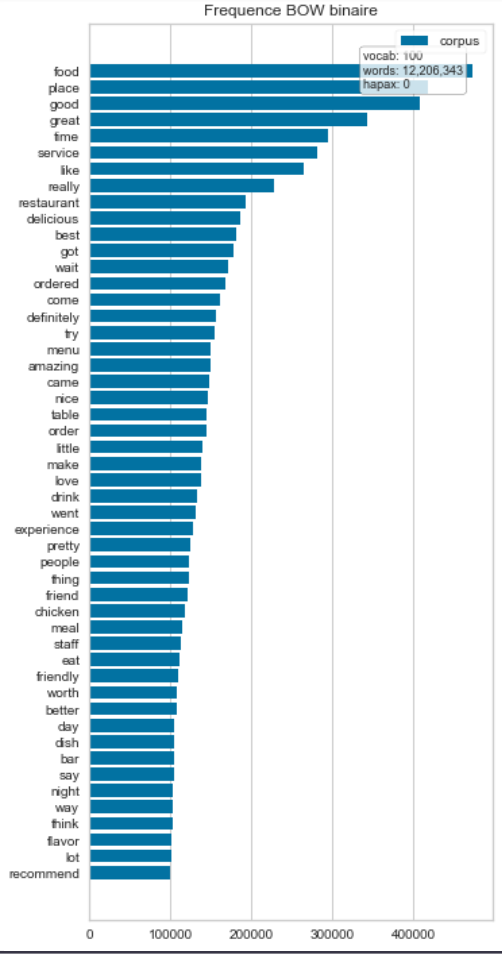

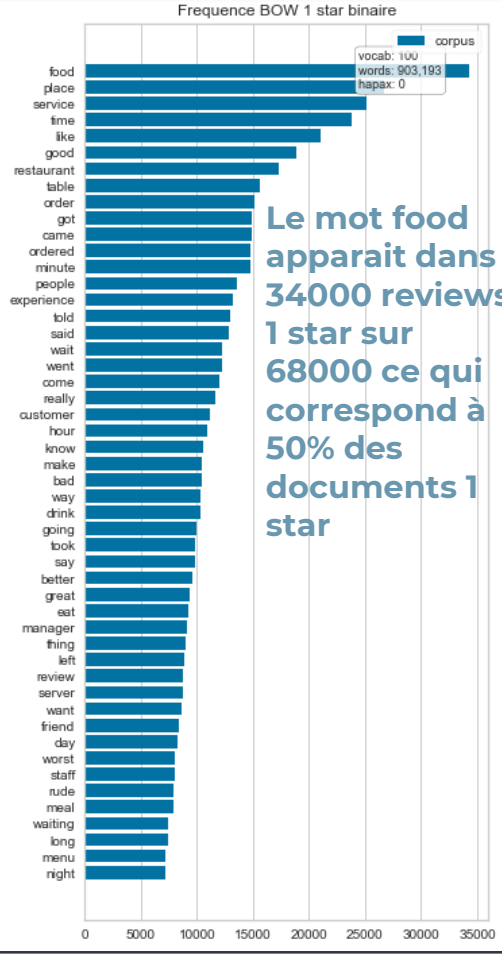

Le mot food apparait dans 34000 reviews 1 star sur 68000 ce qui correspond à 50% des documents 1 star

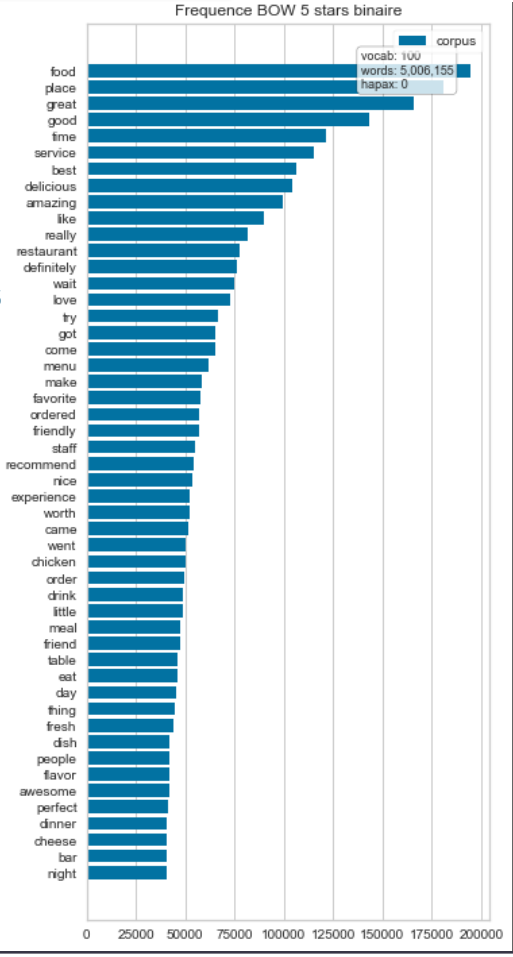

Vectorisation : TF-IDF (permet de donner moins de poids aux tokens trop fréquents et donc peu discriminants)
fonction TfidfVectorizer de sklearn.feature_extraction.text

max_features 100 words/bigrams : l'option binaire (presence ou non du mot dans le document sans comptage multiple par document)

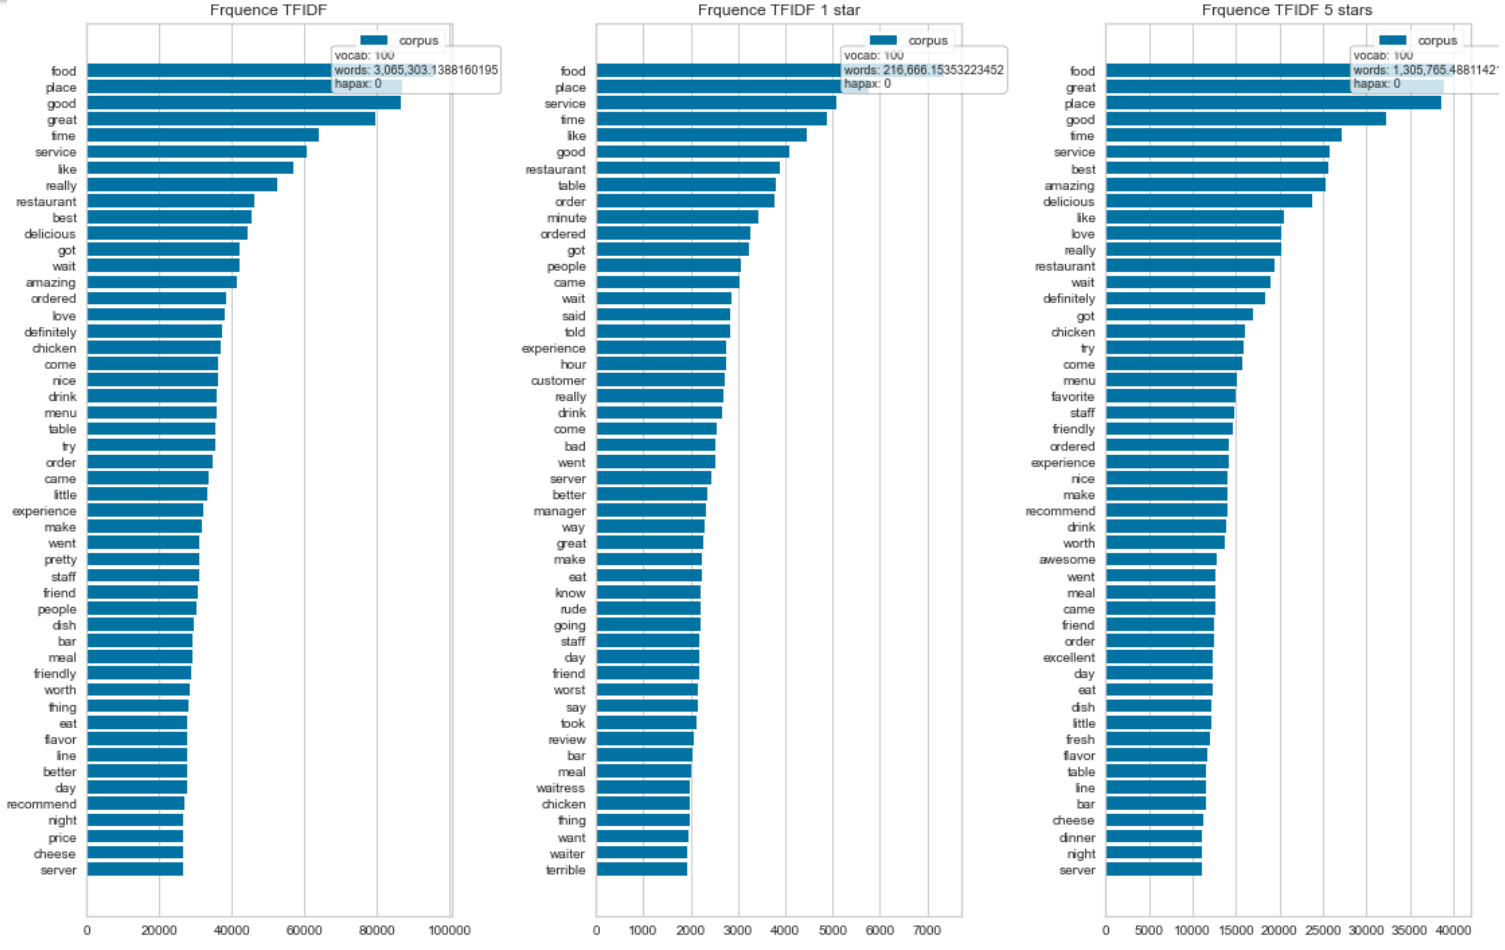

BAD-REVIEWS – TOPIC Modeling – CLUSTERING

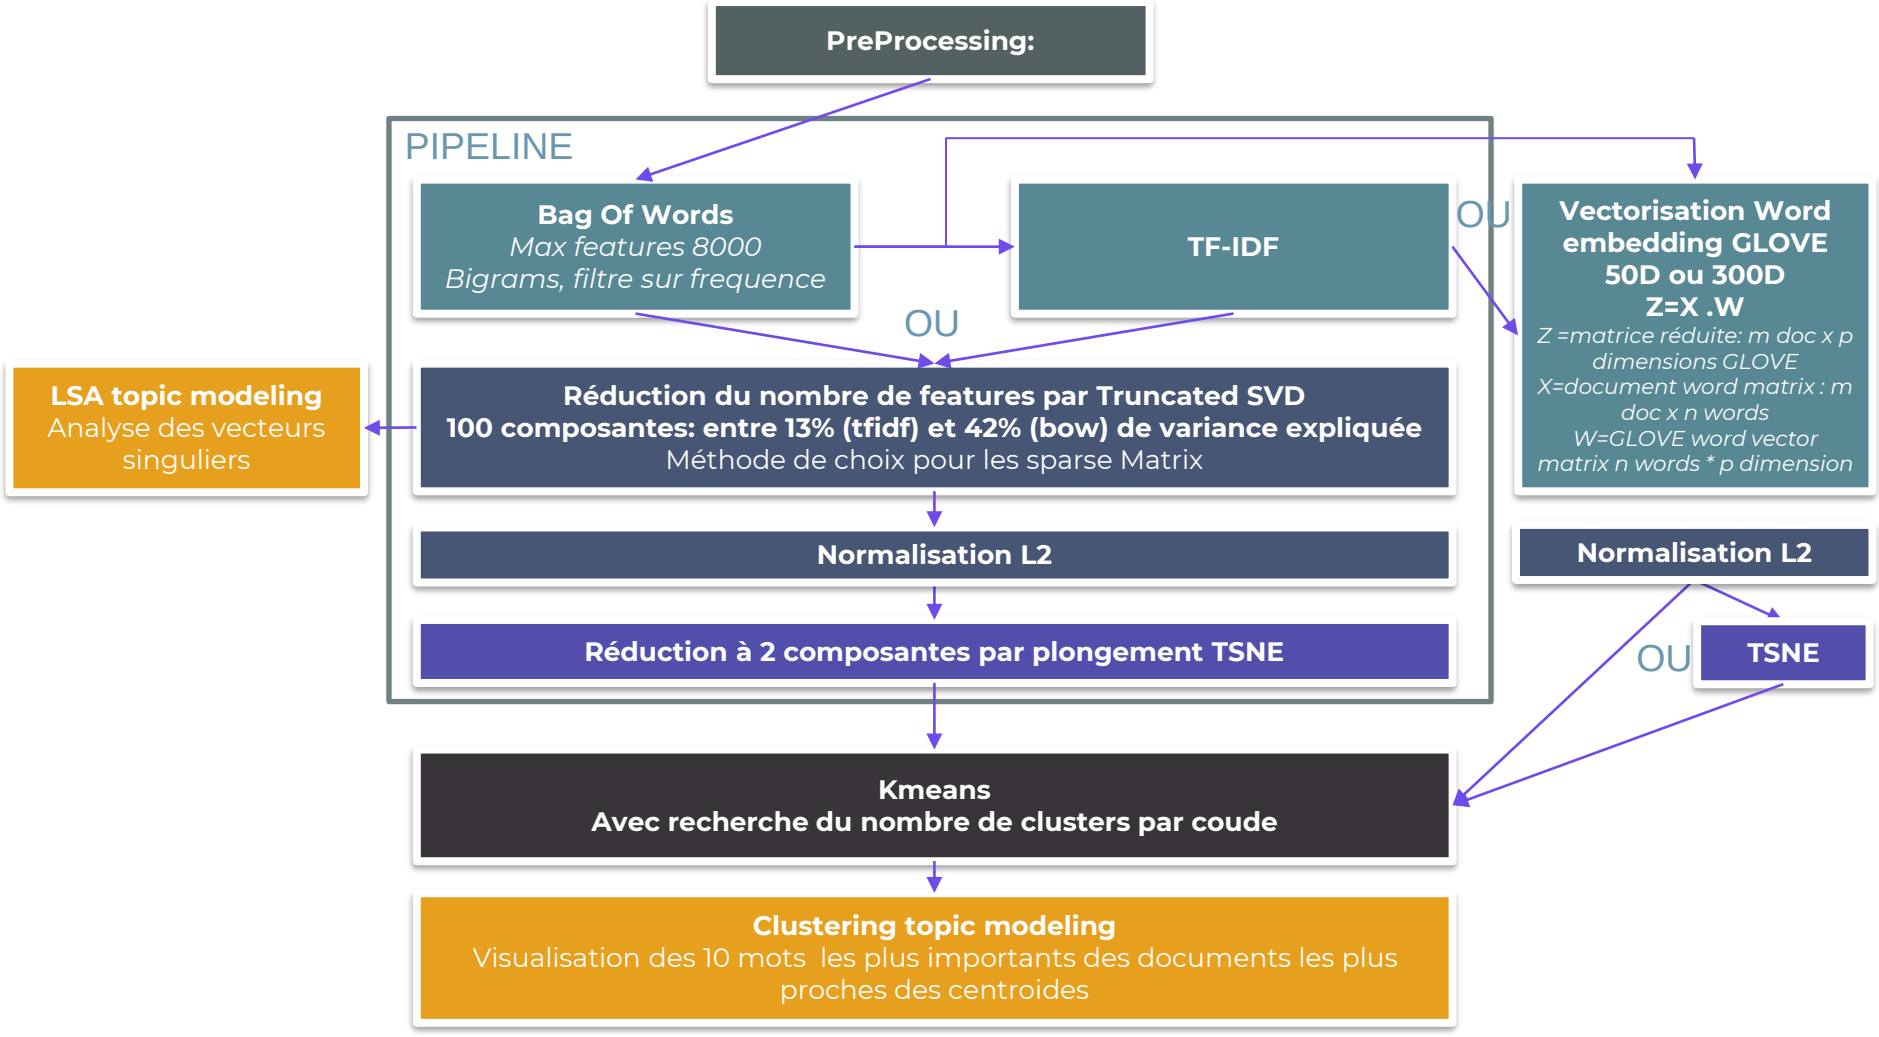

Cas: bag of words: filtre [2%-50%] / max features < 8000 recherche du k -> 4

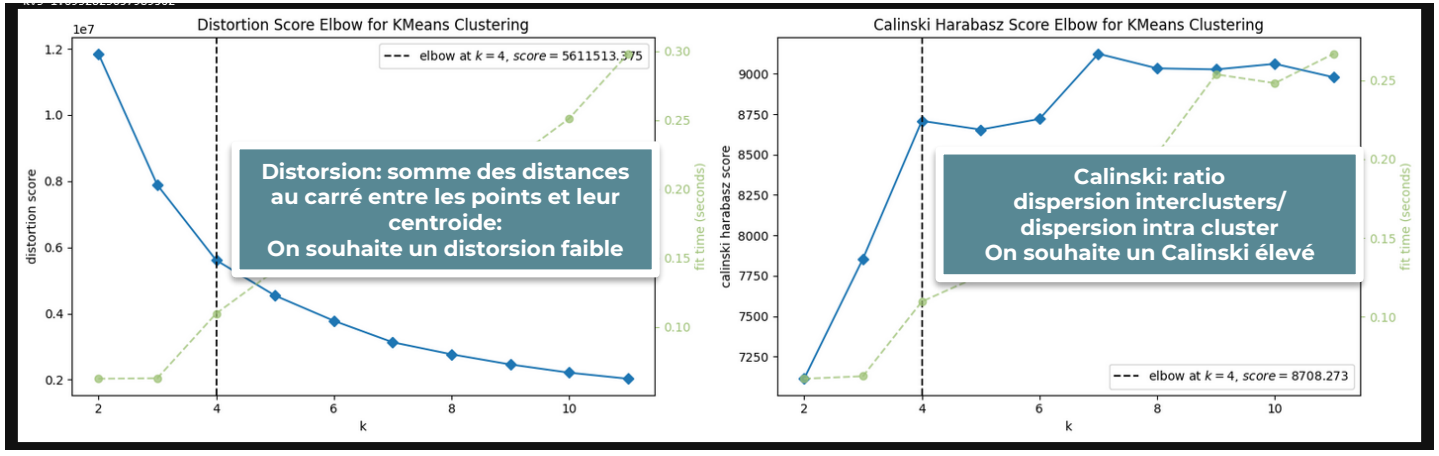

Score de silhouette compris entre -1 et 1:
la différence la distance moyenne avec les points des autres groupes voisins (séparation) et entre la distance moyenne avec les points du même groupe que lui (cohésion)

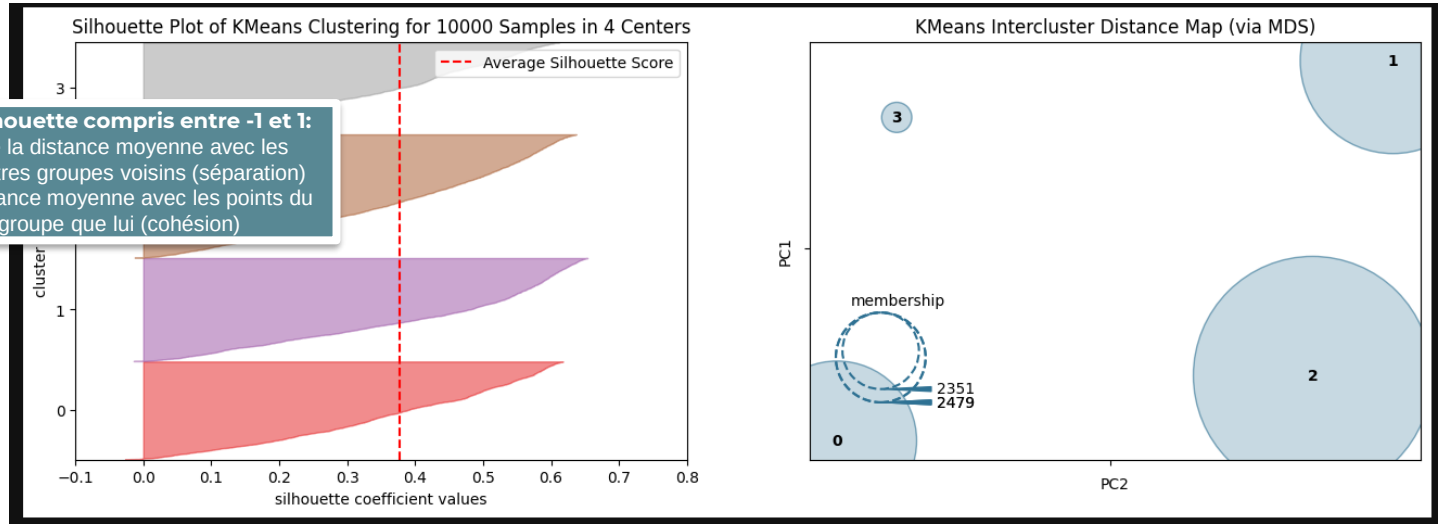

Cas: bag of words – Mots importants des centroides

Visualisation TSNE des clusters

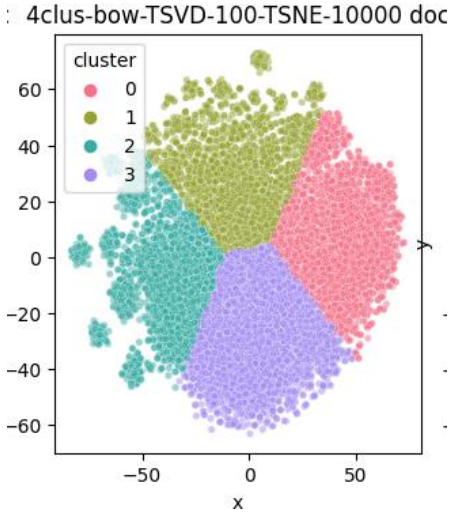

Mots les plus importants des documents les plus proches des centroides

```
Cluster 0 words:[['like' 'minute' 'hour' 'came' 'saw' 'minute later' 'right' 'customer'
  'staff' 'wait']]

Cluster 1 words:[['got' 'meal' 'tried' 'night' 'literally' 'time' 'dollar' 'awful' 'fact'
  'menu']]

Cluster 2 words:[['taste' 'like' 'loud' 'used' 'portion' 'food' 'fish' 'sweet'
  'expensive']]

Cluster 3 words:[['hostess' 'cold' 'like' 'food' 'want' 'waiter' 'friendly'
  'disappointment' 'chicken' 'meal']]
```

Cluster 0 : attente
Cluster 1 : plat, prix
Cluster 2: plat, prix
Cluster 3: service, plat

Documents filtrés les plus proches des centroides des clusters

```
4998   suppose would good ever make oh wait consciously gave someone else never made new lunch today ordered two turkey two transaction sec
ond apart came half hour told mine way ten minute later saw turkey materialize eagerness counter boss um ten minute go another turkey anoth
er customer twenty minute came best part staff try look like right like exist like maybe acknowledge mistake go away got refund demanding s
ince wasted hour life ton attitude food back

3410   night got possibly worst meal ever life tried write e mail give opportunity correct almost week never back ordered dish amazing menu
picture fact almost positive came literally soup butter spent dollar meal tried eat since closed time got nothing could got literally hour
later ended spending night throwing awful experience shame used love think well thanks

5487   sweet careful diabetes loud like fish market except taste like food expensive term portion taste ingredient used

5852   excited trying restaurant disappointment food cold service poor waiter friendly felt rushed entire meal fried chicken cold oxtail gr
it entirely salty honest server unfriendly one staff around like zombie like want exception hostess hostess nice back
```

Cas: TFIDF: filtre [2%-50%] / max features < 8000 recherche du k -> 4

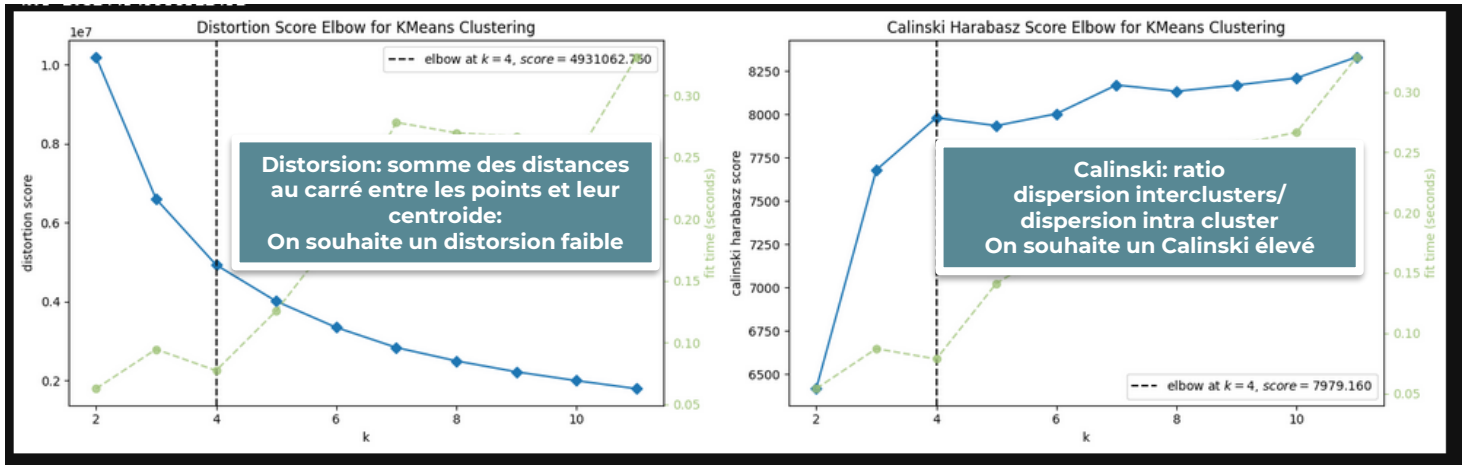

Score de silhouette compris entre -1 et 1:
la différence la distance moyenne avec les points des autres groupes voisins (séparation) et entre la distance moyenne avec les points du même groupe que lui (cohésion)

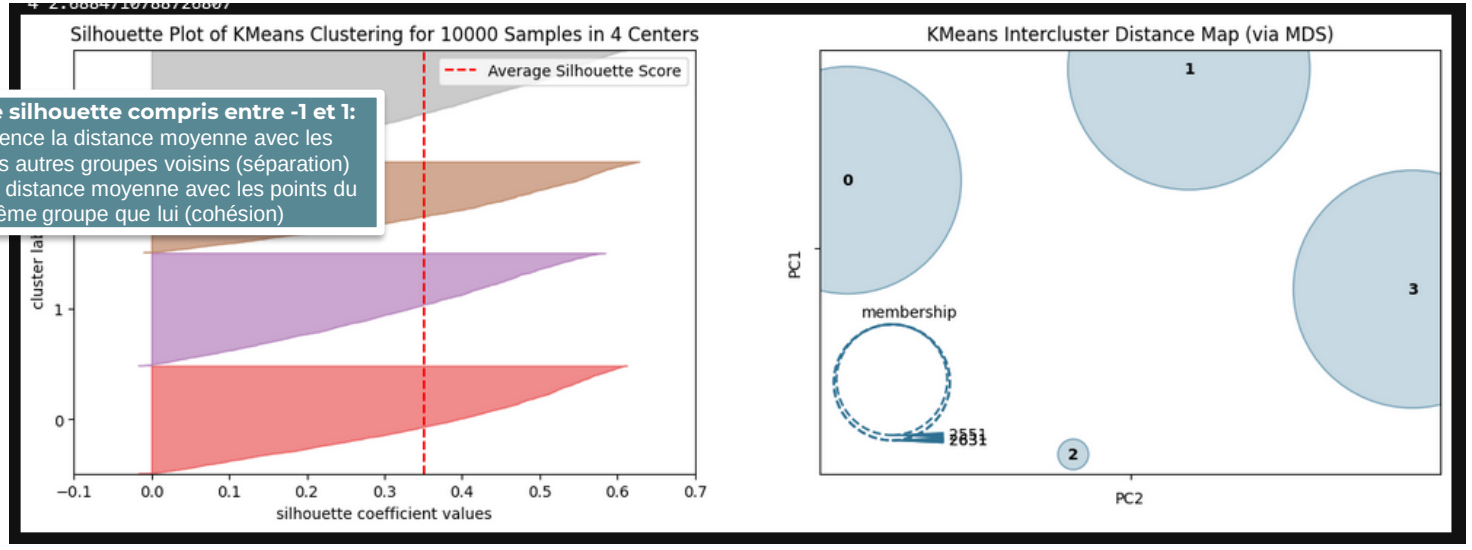

Cas: TF-IDF– Mots importants des centroides

Visualisation TSNE des clusters

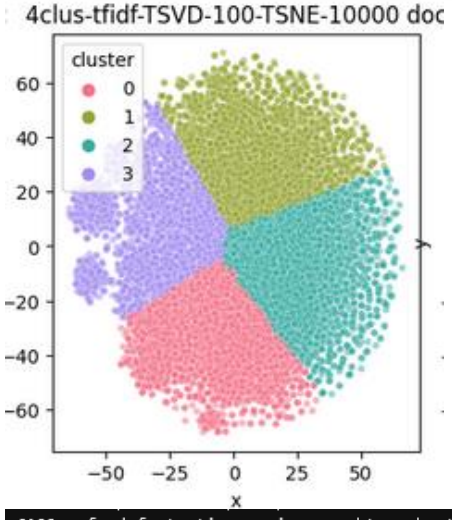

Mots les plus importants des documents les plus proches des centroïdes

```
Cluster 0 words:[['food good' 'attitude' 'love' 'trying' 'busy' 'gave' 'need' 'cold'
  'ask' 'check']]

Cluster 1 words:[['morning' 'suck' 'forgot' 'word' 'house' 'entire' 'literally' 'high'
  'feel' 'person']]

Cluster 2 words:[['chef' 'matter' 'idea' 'soon' 'cook' 'speak' 'breakfast' 'potato'
  'believe' 'egg']]

Cluster 3 words:[['based' 'chance' 'pick' 'unless' 'short' 'average' 'giving' 'course'
  'steak' 'quite']]
```

Cluster 0 : food, service
Cluster 1 : service
Cluster 2: food
Cluster 3: ?

```
6129   food fantastic service caught much attitude place go back last time gave try two server busy chatting behind bar place full waiting
five minute ask table got cold stare told would minute chat left love food good need put like hobo trying check

1026   like food taste like something forgot microwave night robber forced eat upon breaking house morning look wall literally like high sc
hool gym floor smell ambience restaurant carried repulsive odor ground literally like construction crew dirt paint throughout entire restau
rant random imagery word painted across place like selected crazy person random choose put lightly place suck like feel like garbage eat ga
rbage place

9605   husband went breakfast thought order southern breakfast husband ordered simple breakfast egg medium potato sausage toast breakfast c
ame egg cold told server egg cold removed plate table moment later brought dish back minus egg said egg soon minute egg time everything els
e dish cold speak manager wrong decision part manager person ever dealt service position told could would cook bring hot egg another manage
r came said would check chef making new egg chef owner please customer told would serve leave believe owner would say never dealt person pe
rson idea customer service moral story eat send like matter

8571   many better steak house option city actually would honor business would stay away capital grill least sort quality service quite pos
sibly worst city tend eat bar every time go often find getting sort quality service capital grill come request almost like hook check avera
ge meaning ask get even ask guarantee actually get unless regular course short based bartender capital grill almost appear union mentality
work ethic riding gravy train completely fact good service high check average money cater little interest grow customer base rather pick al
ternative steak house many better one city would love business place stink done giving yet another chance good luck
```

Documents filtrés les plus proches des centroides des clusters

Cas: TFIDF: filtre [1%-40%] / reduction word embedding GLOVE 50D recherche du k -> 4/5

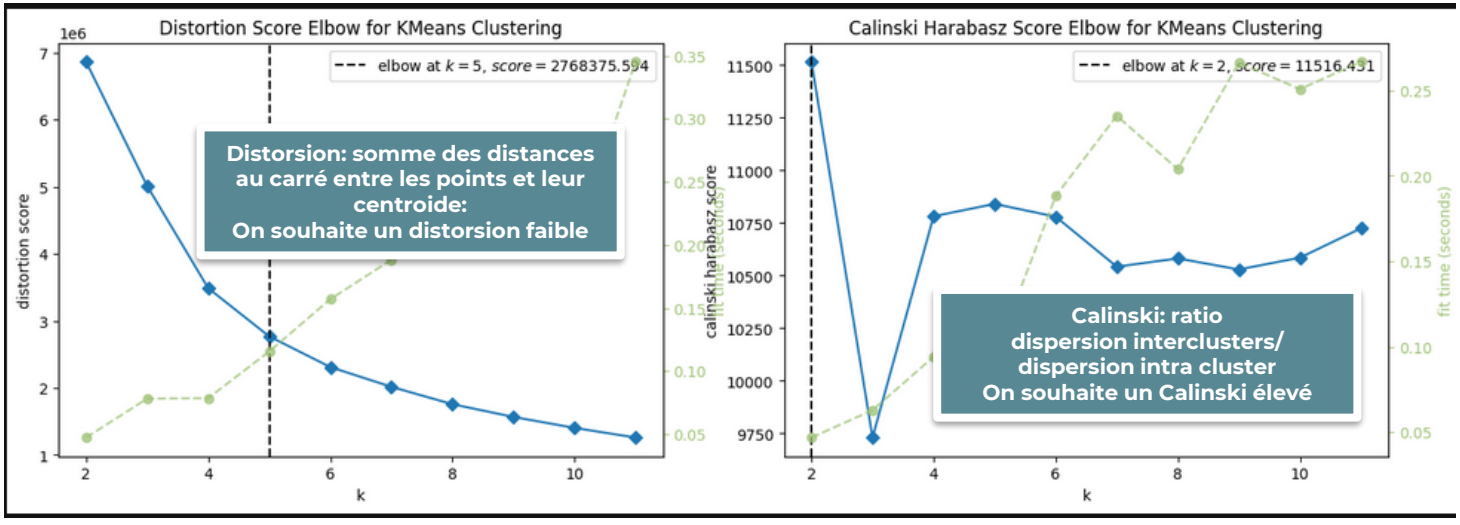

Score de silhouette compris entre -1 et 1:
la différence la distance moyenne avec les points des autres groupes voisins (séparation) et entre la distance moyenne avec les points du même groupe que lui (cohésion)

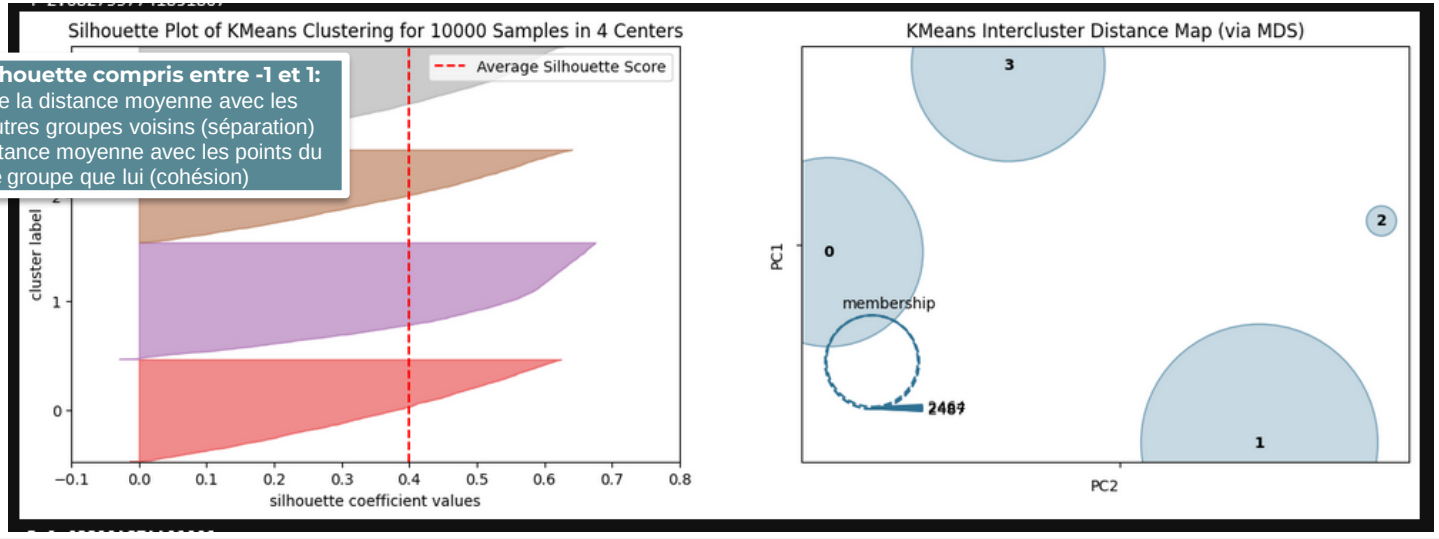

Cas: TF-IDF- GLOVE– Mots importants des centroides

Visualisation TSNE des clusters

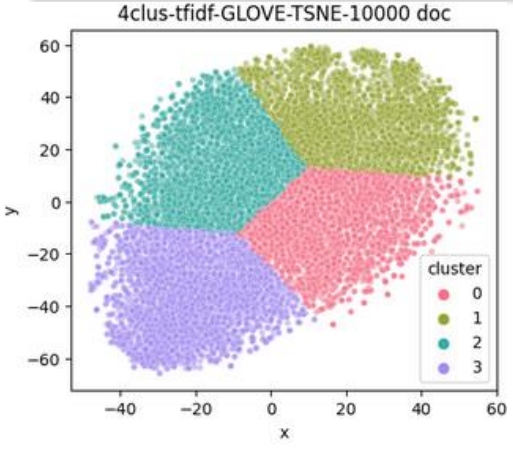

Mots les plus importants des documents les plus proches des centroïdes

```
Cluster 0 words:['love' 'simple' 'thanks' 'local' 'breakfast' 'excited' 'reason' 'home'
 'pretty' 'tried']

[1327 2551  865  129  891 9454 2313 1551   50  117]
Cluster 1 words:['husband' 'restaurant' 'manager' 'group' 'leave' 'reservation' 'stated'
 'host' 'new' 'like']

[20405   154   362  1522  7635  2004  9956  4906  1633 86908]
Cluster 2 words:['waiter' 'told' 'head' 'knew' 'pork' 'extra' 'awful' 'kitchen' 'seat'
 'thats']

[ 5795   823  3806 20631  2529  3017   460  6969  2056   495]
Cluster 3 words:['cheese' 'hand' 'meat' 'lettuce' 'picked' 'hair' 'order' 'checked'
 'clearly' 'issue']
```

Cluster 0 : food, service
Cluster 1 : service
Cluster 2: food, atmosphere, service
Cluster 3: food

Documents filtrés les plus proches des centroides des clusters

```
9397   there reason get excited place menu simple enough make home thanks mi tried love love mister breakfast pancake pretty boring local f
ind back

6277   option leave zero star would review quite different even get opportunity eat restaurant however made reservation group restaurant bi
t early checked informed added another guest reservation stated full please wait door husband went back ask bar see first come first serve
disappointed expressed back group manager husband used profanity towards host husband speaking wife said put kind behavior away husband wen
t host area manager husband appreciate unprofessional coming group like concern something issue correct way handle customer manager stated
need leave felt underneath restaurant black couple leave restaurant term something wrong never like typically travel spend weekend multiple
time year never step foot restaurant manager ashamed acting like towards new customer eat restaurant even get table reservation made day ad
vanced sorry respect mean trying new restaurant

569   review wack want seat party separate table told hurry order kitchen extra sheet dim sum could split check waiter away shaking head be
sides horrible service might worst cuisine ever thats broad umbrella pork dumpling uncooked told waiter awful food waiter said really alrea
dy knew

8997   order al carbon substituted meat lettuce due dietary restriction dairy meat upon arrival checked order find cheese even come al carb
on waitress could remake cheese although clearly looking took hand bring right back obvious someone hand picked cheese caught attitude some
one else deliver new issue also hair side first experience nightmare
```

Latent Semantic Analysis (BOW) – analyse des premiers vecteurs singuliers qui peuvent etre vus comme des concepts/topics

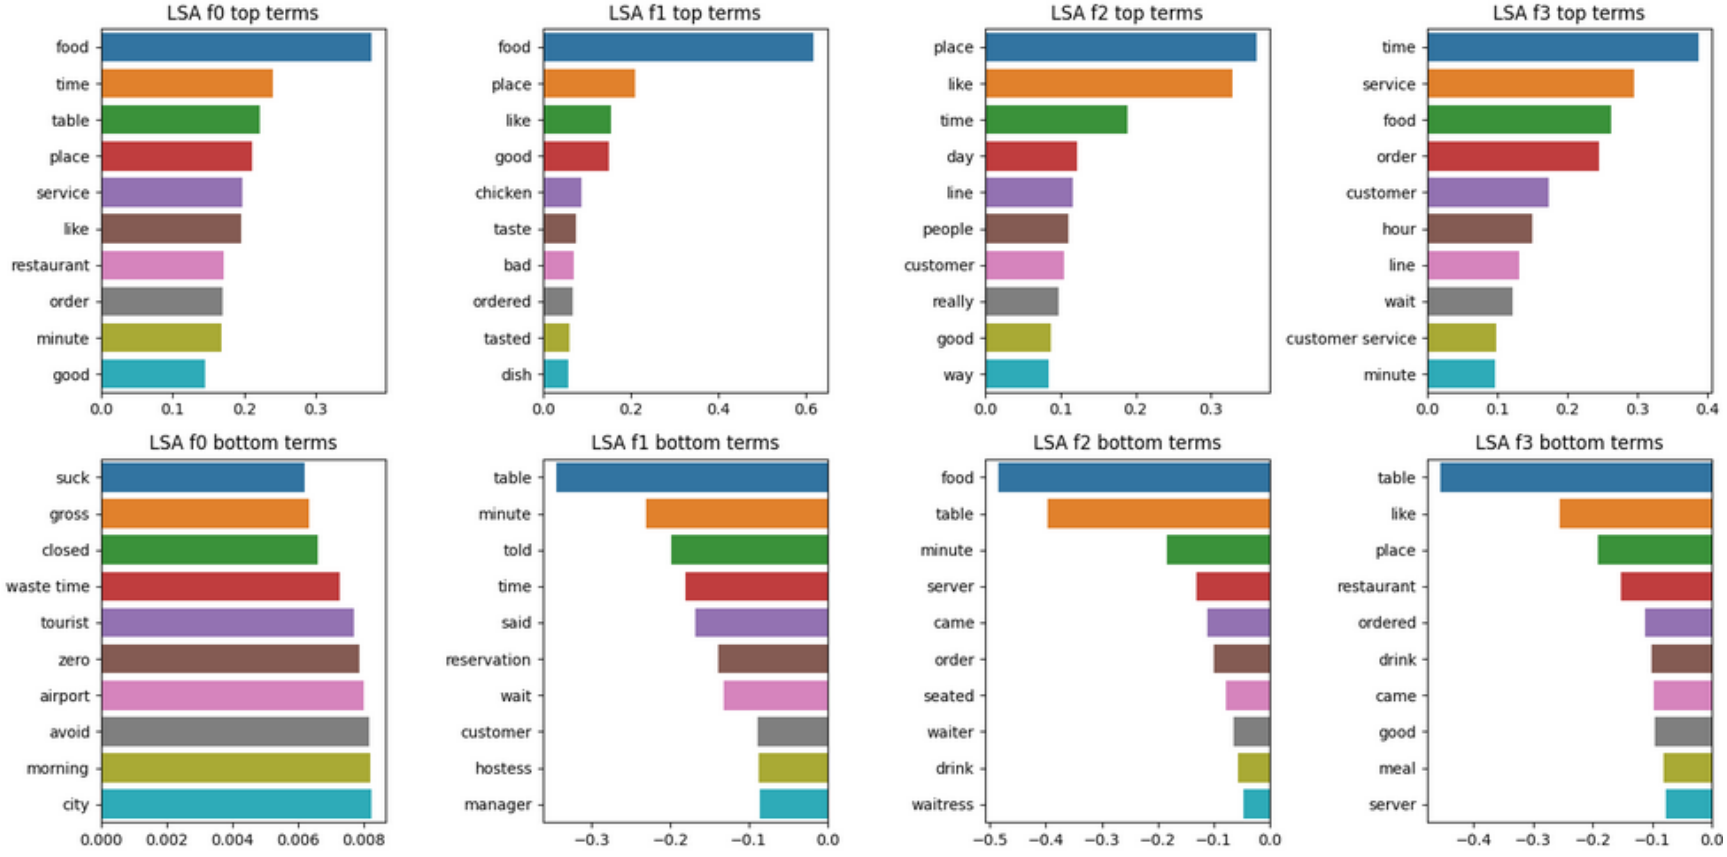

Latent Dirichlet Allocation – LDA – Topic Modelling

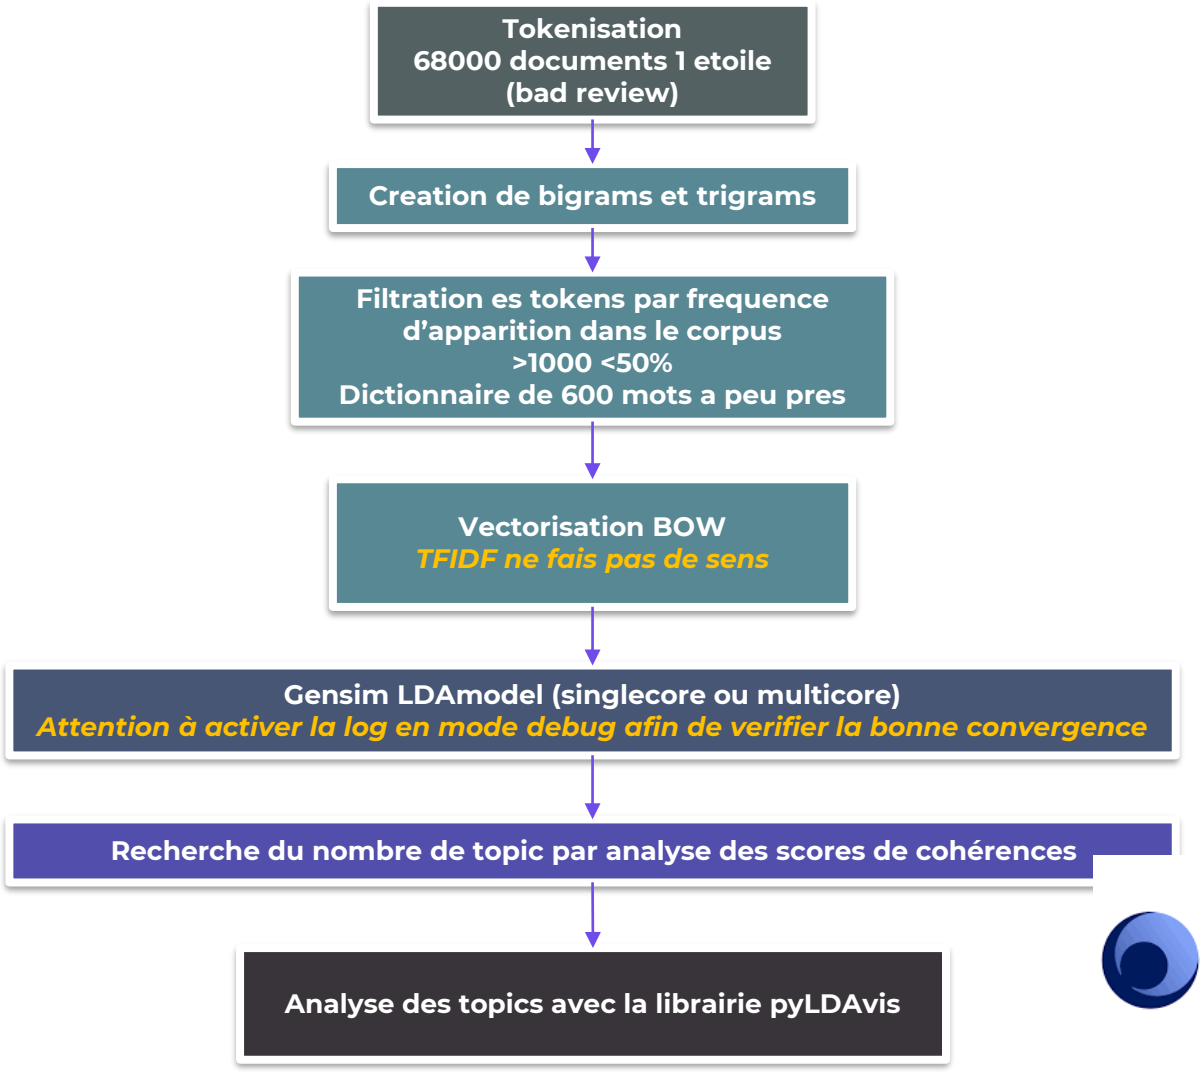

GENSIM
topic modelling for humans

Mesure de cohérence – pipeline de 4 étapes

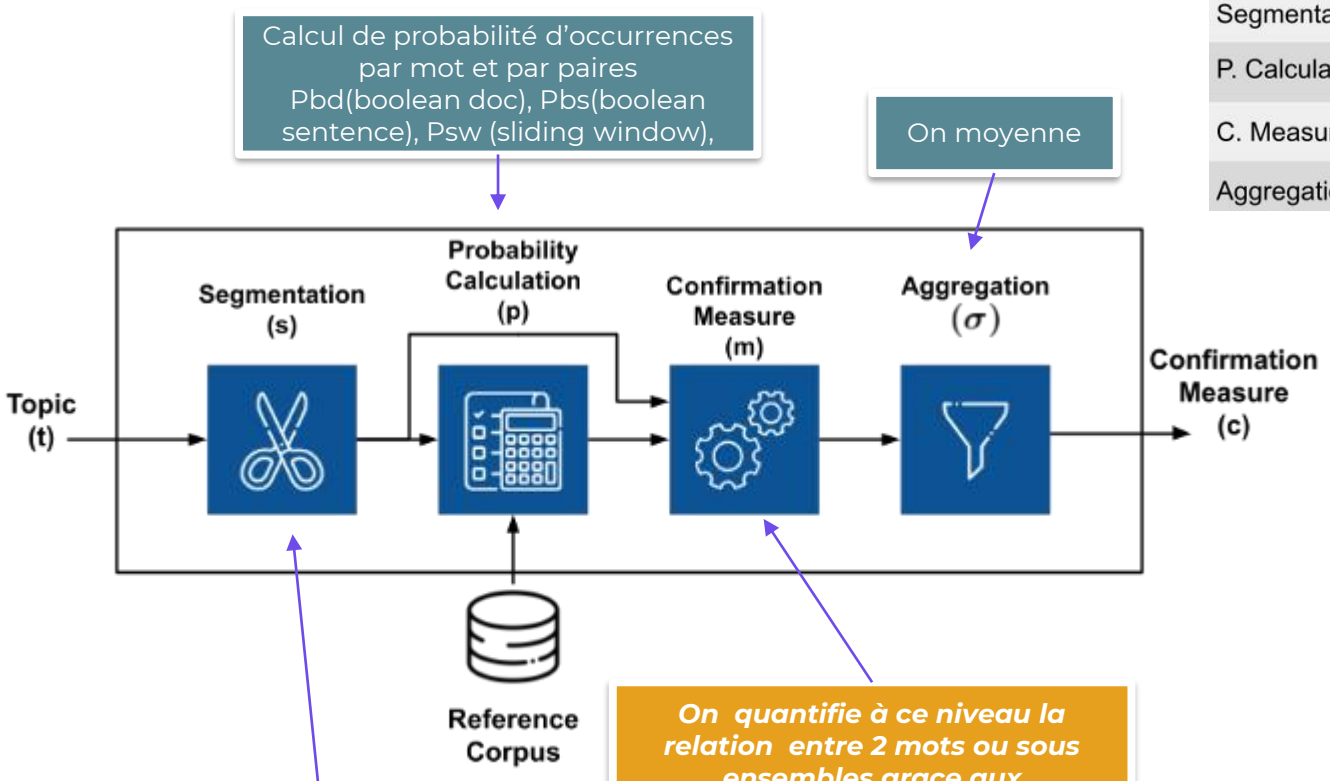

Calcul de probabilité d'occurrences par mot et par paires Pbd(boolean doc), Pbs(boolean sentence), Psw (sliding window),

On moyenne

Name	C_V	C_{UMass}
Segmentation	S^{one}_{set}	S^{one}_{pre}
P. Calculation	$P_{sw(110)}$	P_{bd}
C. Measure	$\tilde{m}_{\cos(nlr)}$	m_{lc}
Aggregation	σ_a	σ_a

Sliding windows de 110

Moyenne arithmétique

Mesure indirecte avec cosinus similarité

Création de sous ensembles de paires de mots împortants pour chaque topic
Paire one-one
Paire one-all etc„

On quantifie à ce niveau la relation entre 2 mots ou sous ensembles grace aux probabilités,
Plusieurs fonctions directes (A et B souvent ensemble) ou indirectes (A et C puis B et C souvent ensembles

Latent Dirichlet Allocation – LDA – Topic Modelling

U mass cohérence
entre -14 et +14

Cohérence score:
Mesure de similarités sémantiques entre 2 mots à score élevé du même topic

C_V cohérence entre 0 et +1
0.3 mauvais
0,4 à ameliorer
0,6 bon
0,7 tres bien
Au dessus: improbable

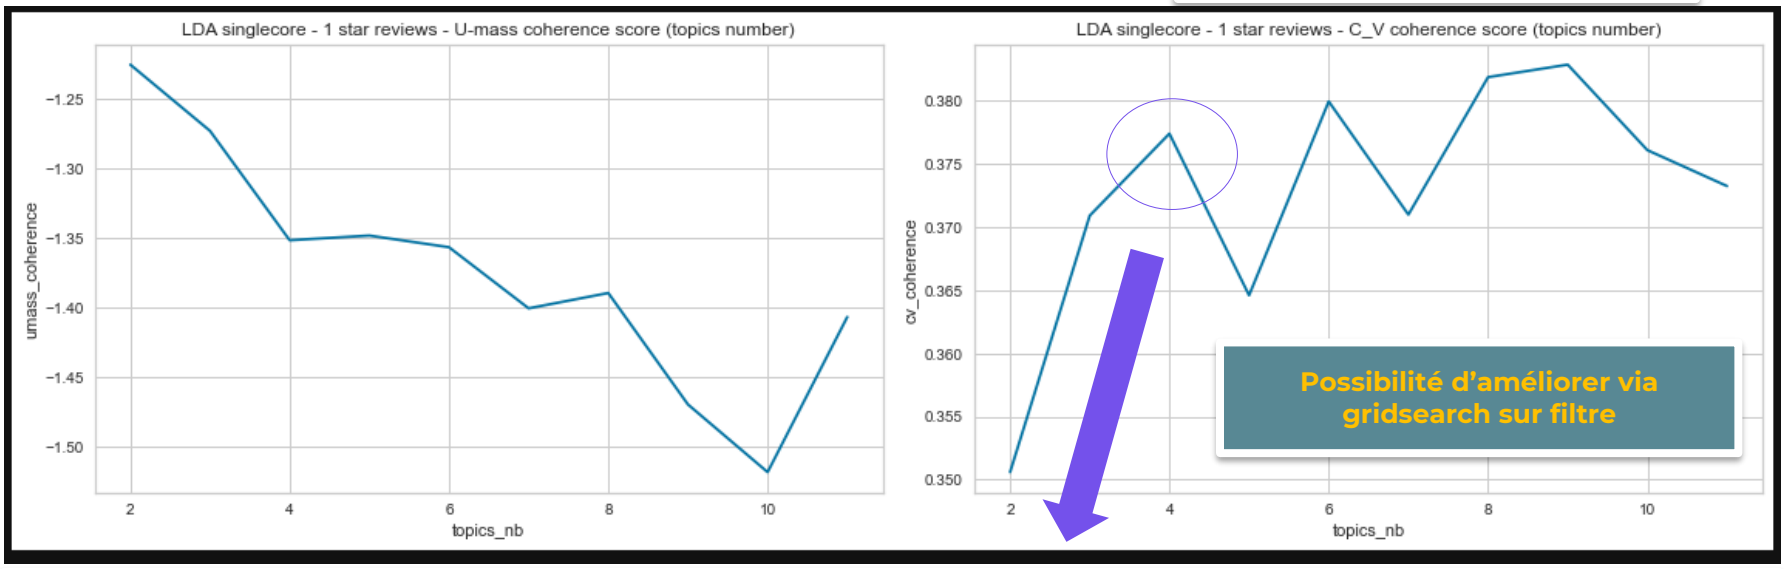

TOPIC 1 : servie & attente :'0.024*"table" + 0.017*"told" + 0.016*"minute" + 0.016*"would" + 0.015*"order" + 0.014*"wait" + 0.014*"time" + 0.014*"said" + 0.013*"get" + 0.012*"restaurant

TOPIC 2: food & service: '0.033*"food" + 0.018*"service" + 0.014*"came" + 0.014*"ordered" + 0.013*"restaurant" + 0.013*"time" + 0.013*"server" + 0.013*"order" + 0.012*"one" + 0.012*"table"

TOPIC 3: food & service: '0.028*"**food**" + 0.026*"place" + 0.019*"get" + 0.017*"time" + 0.015*"go" + 0.014*"like" + 0.013*"people" + 0.012*"service" + 0.011*"one" + 0.011*"good

TOPIC 4: food & gout, '0.030*"food" + 0.023*"place" + 0.019*"good" + 0.015*"like" + 0.013*"ordered" + 0.011*"one" + 0.011*"restaurant" + 0.009*"even" + 0.009*"taste" + 0.009*"would

Latent Dirichlet Allocation – LDA – Topic 1

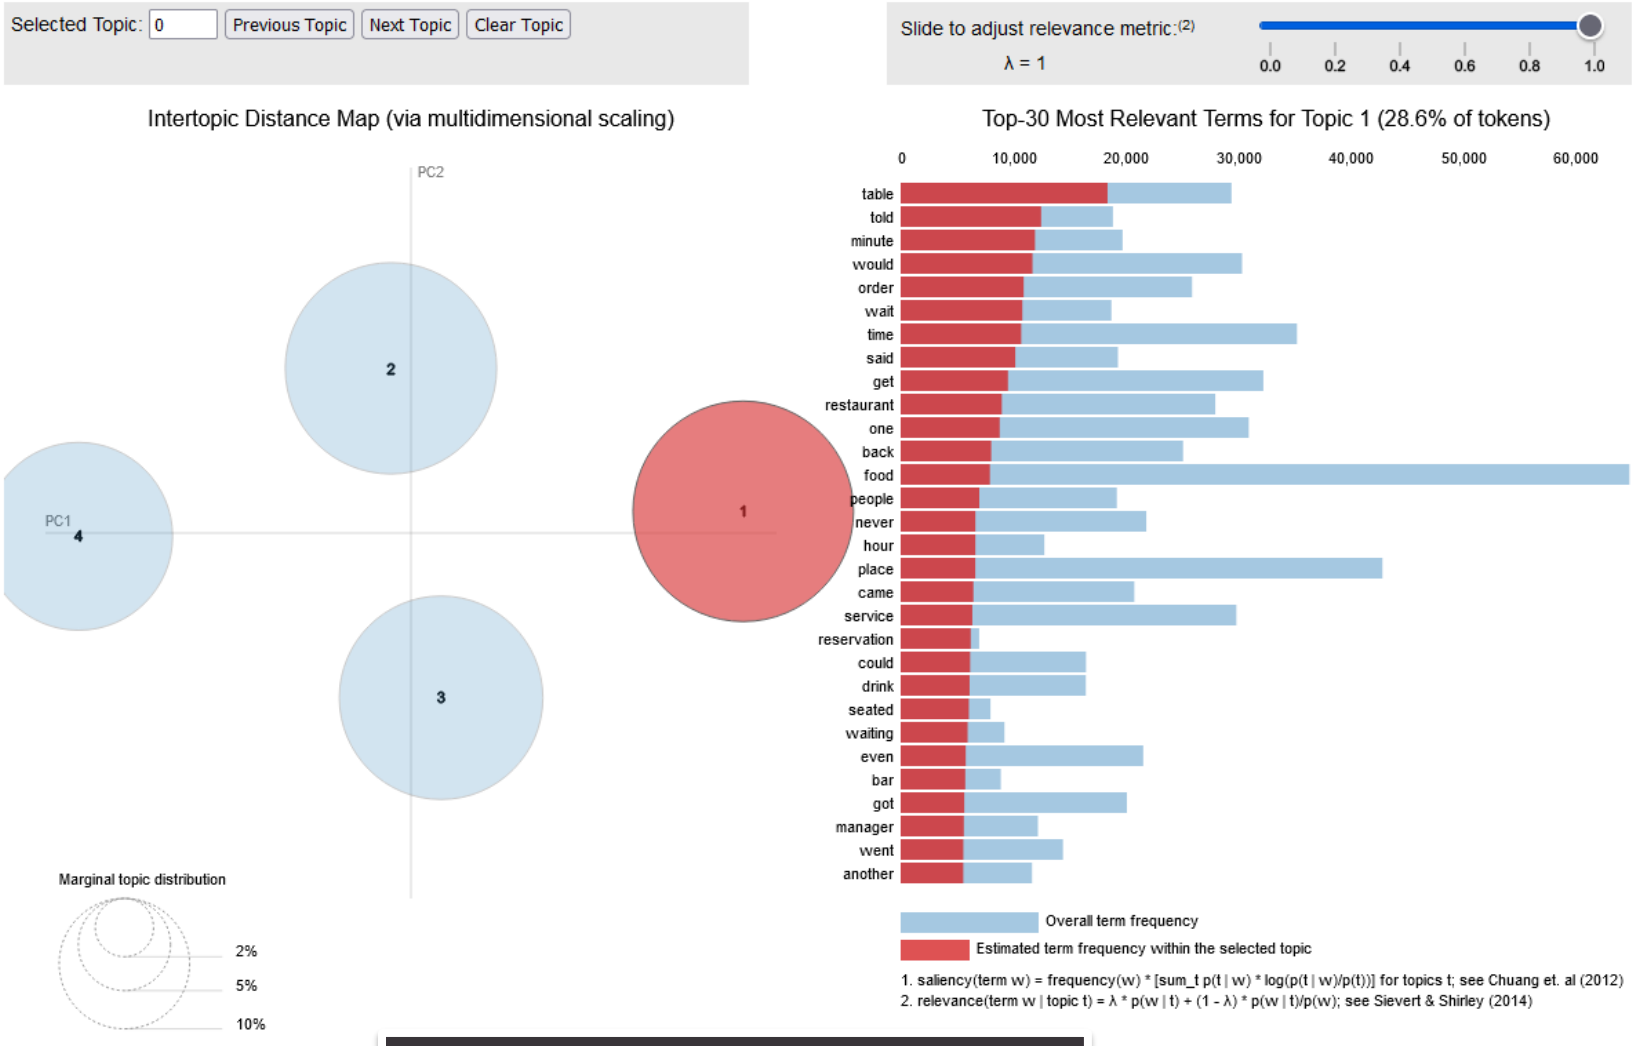

TOPIC 1: service/attente

Latent Dirichlet Allocation – LDA – Topic 2

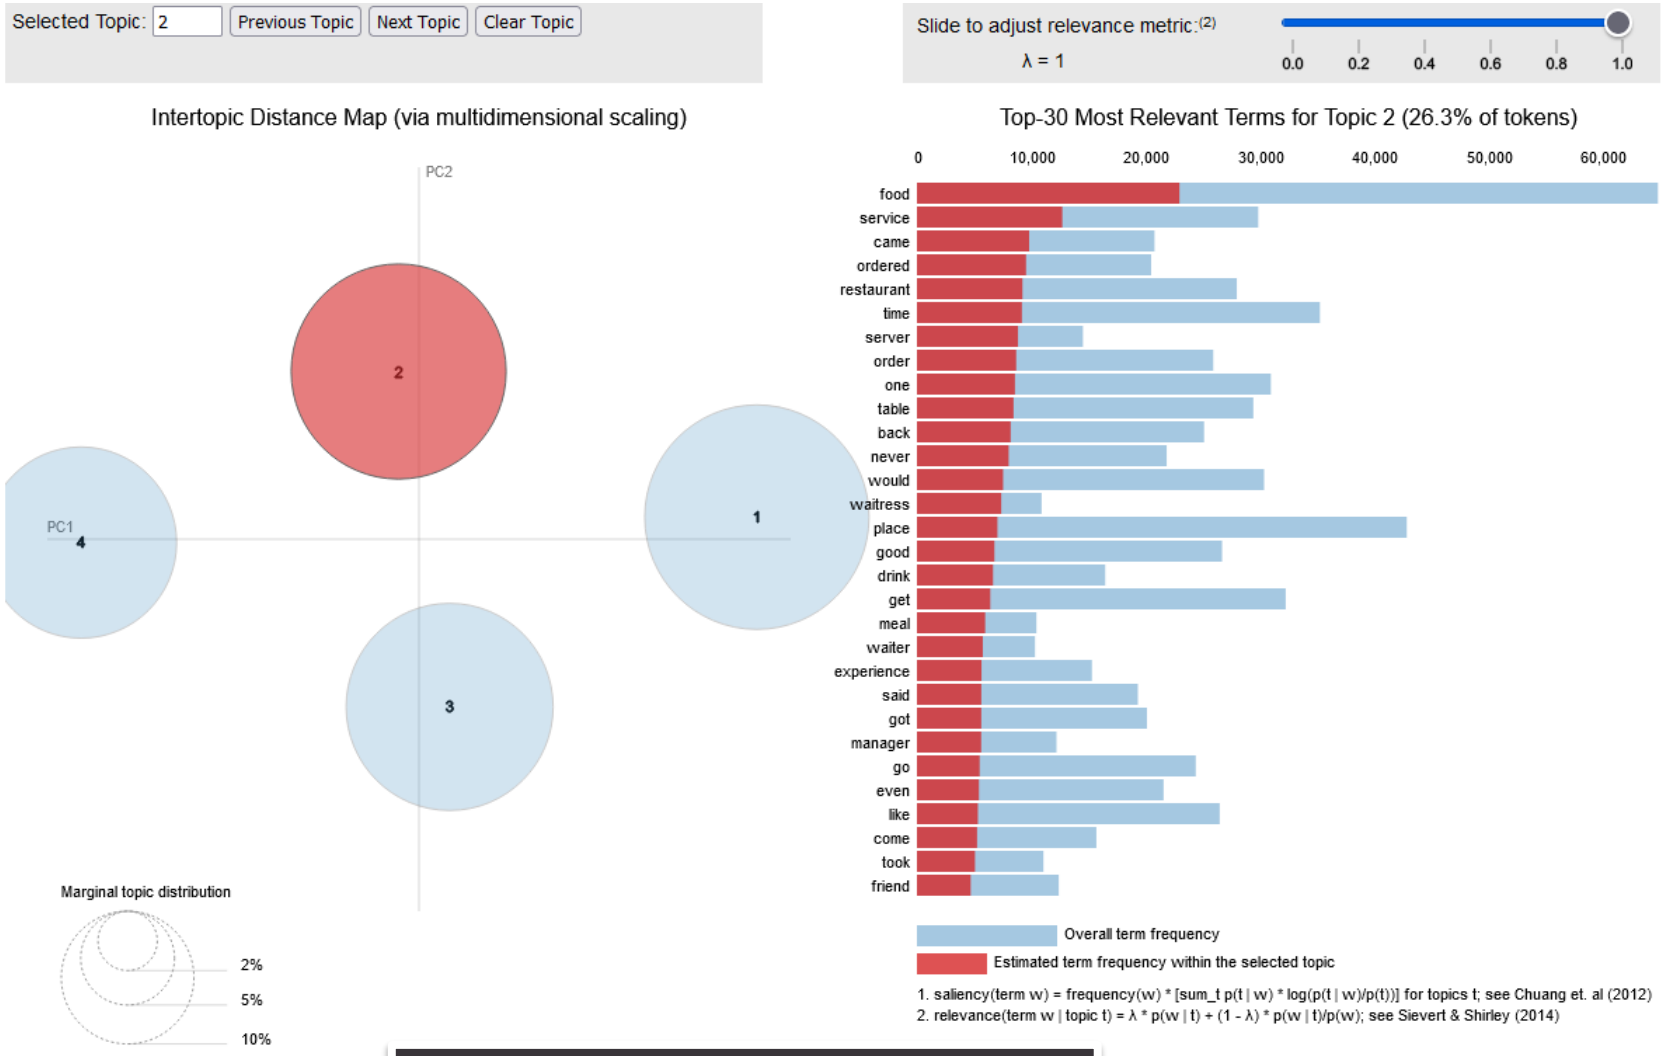

Topic 2: food & service

Latent Dirichlet Allocation – LDA – Topic 3

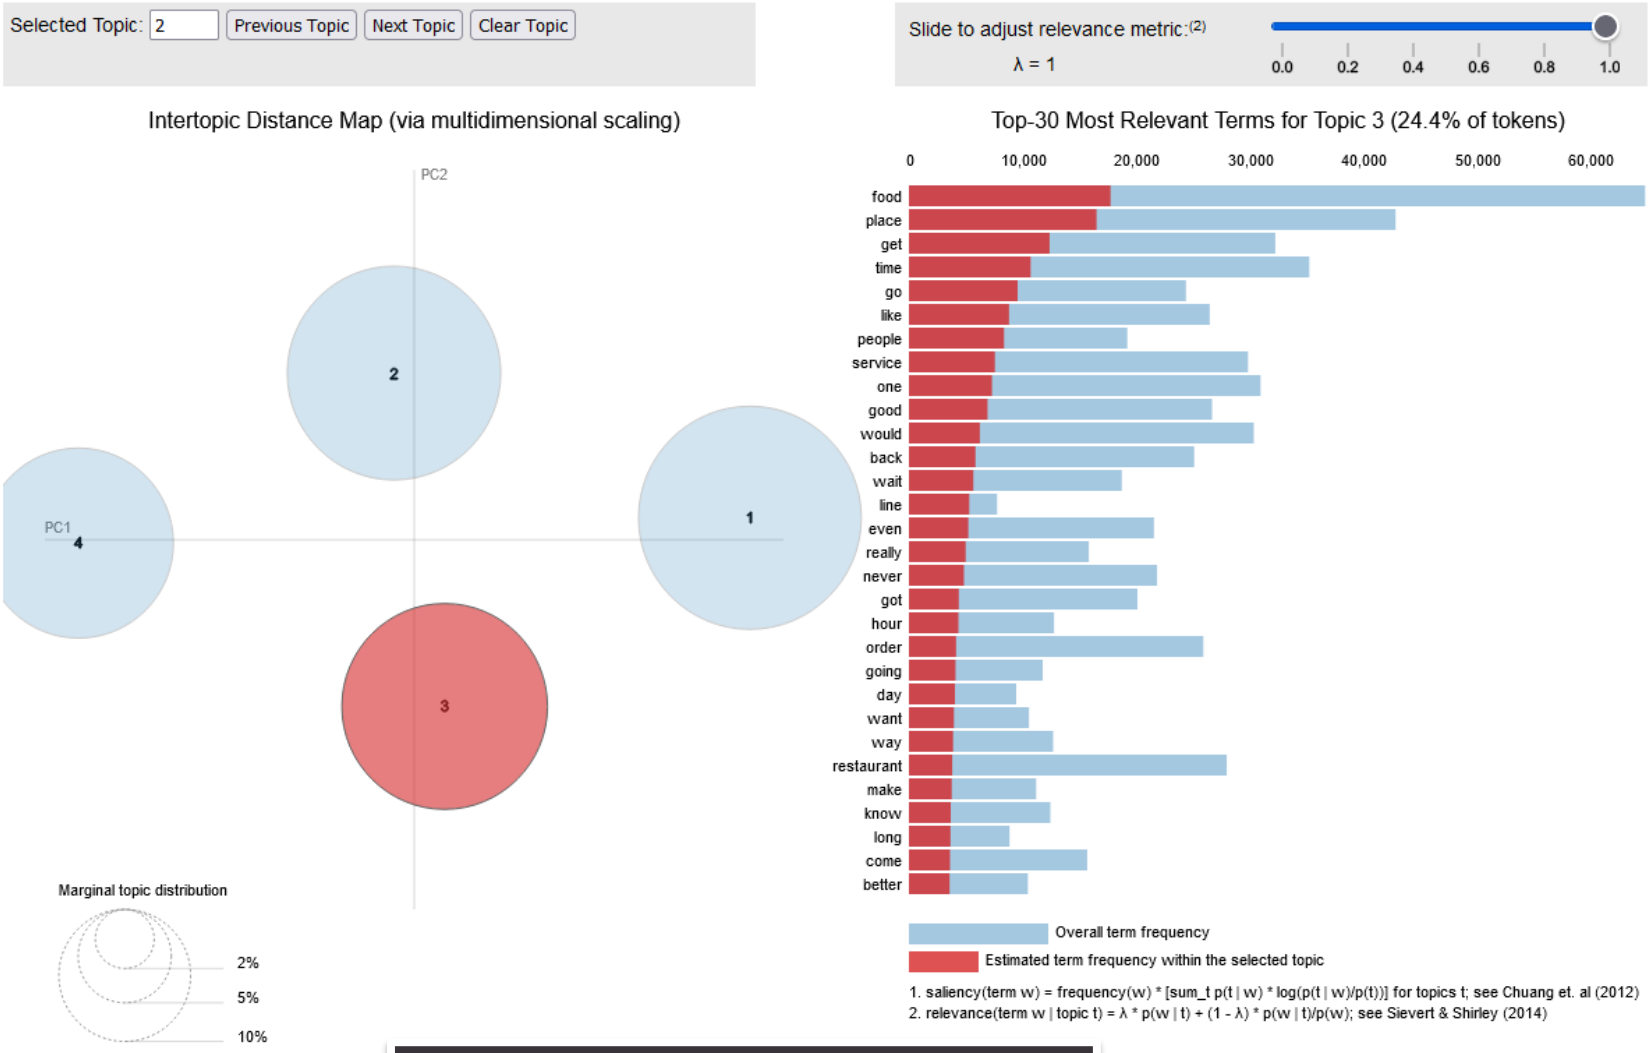

Topic 3: food & service

Latent Dirichlet Allocation – LDA – Topic 4

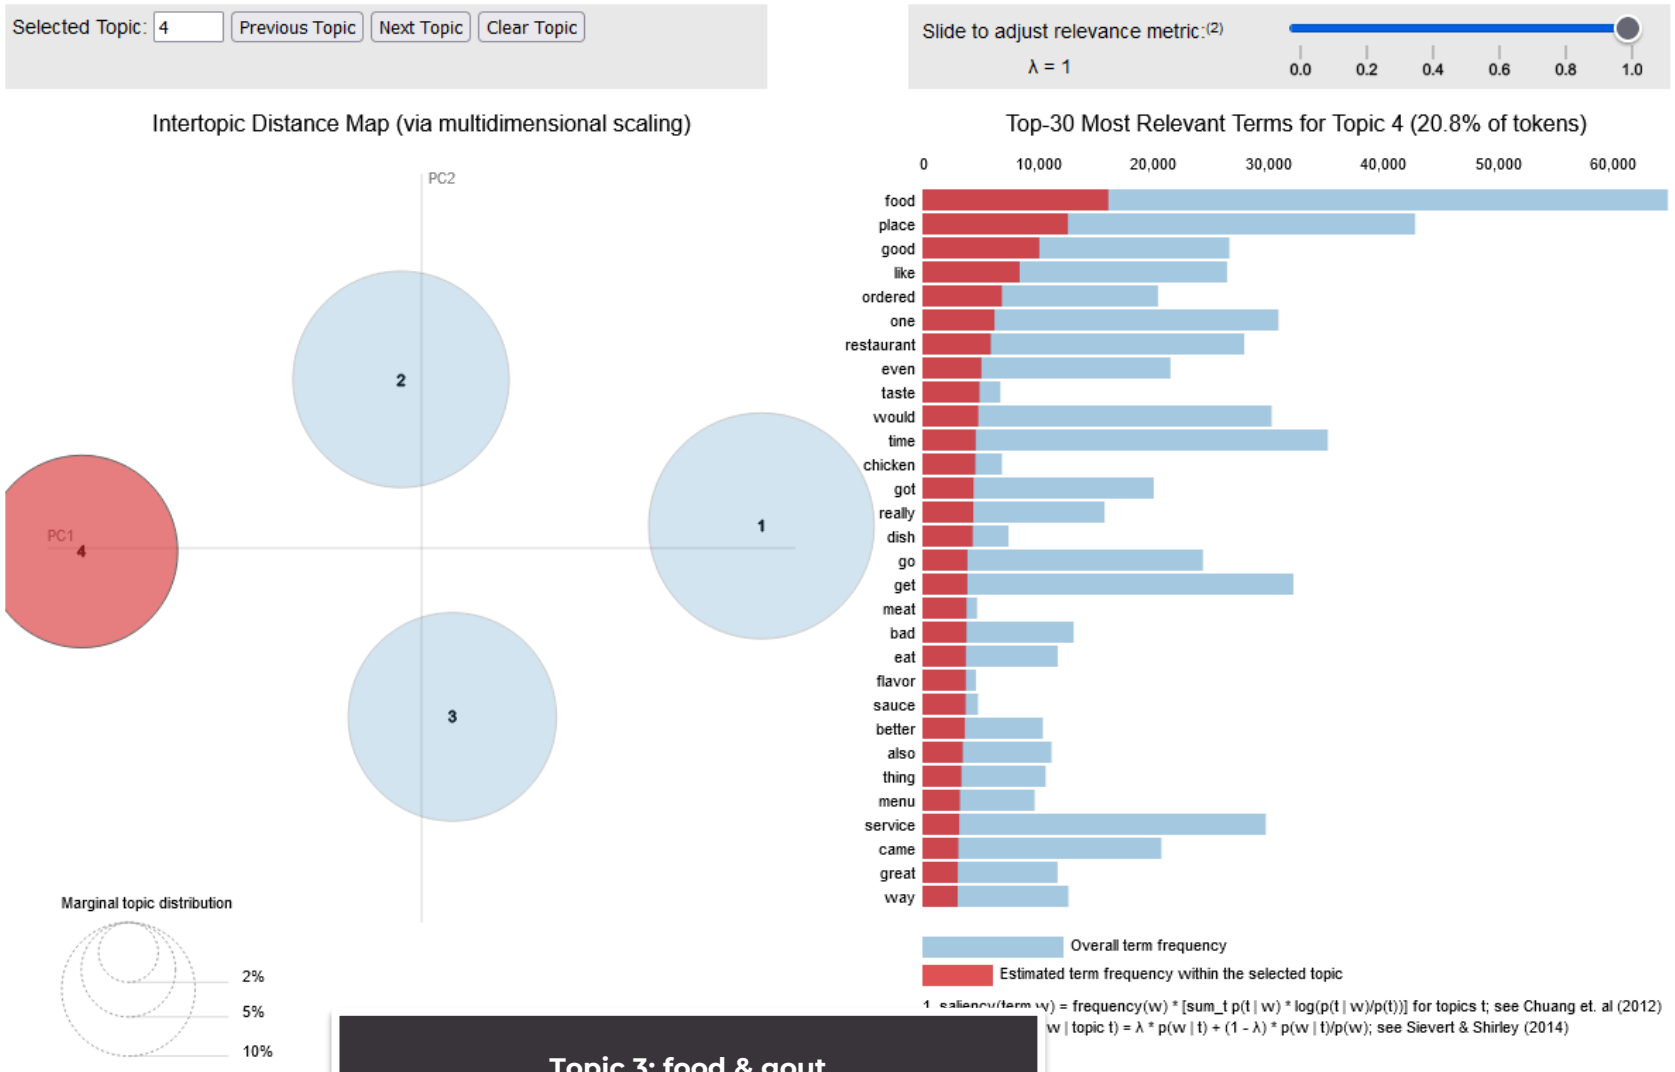

Topic 3: food & gout

C

PROJET VISUALISATION: ANALYSER LES PHOTOS POUR DÉTERMINER LES CATÉGORIES DES PHOTOS

Analyse rapide des images YELP

DownLoad du fichier image yelp .TAR:
https://www.yelp.com/dataset
puis décompression

↓

Lecture du fichier json de description des images

↓

Split du fichier : entrainement / test
En veillant à garder la structure equilibrée des labels

Infos principales:
Images portant sur 39438 business
200000 photos / 5 labels equilibrés

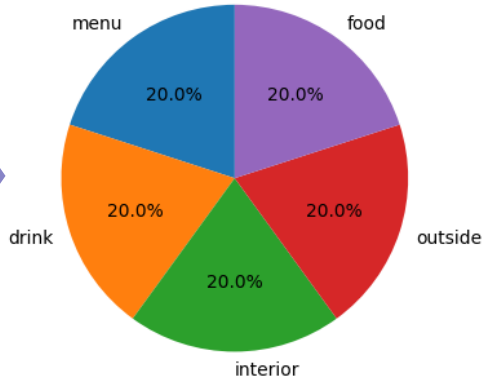

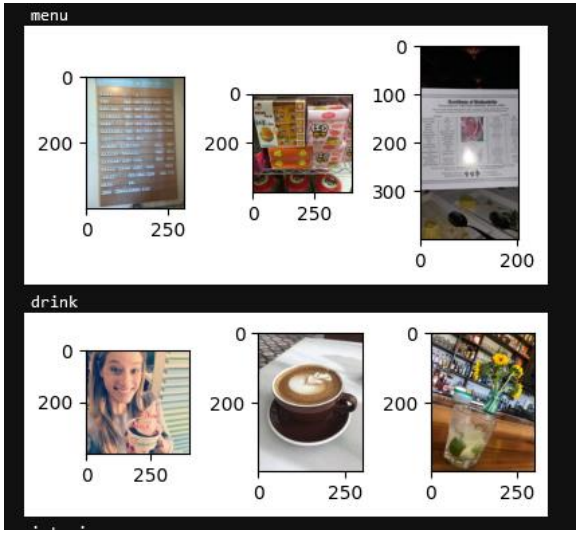

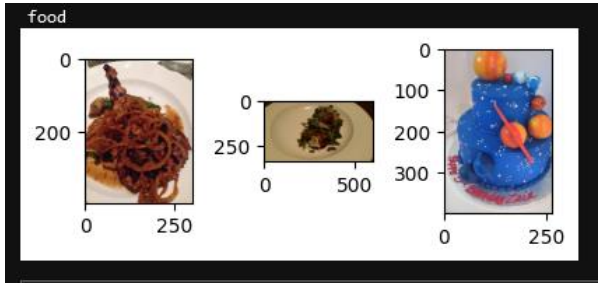

Préprocessing avec

OpenCV

Lecture de l'image en nuances de gris

Denoising avec la fonction fastNlMeansDenoising: Attention ane pas prendre un h trop grand au risque de trop lisser/ floutter la photo

Equalization avec la fonction equalizeHist Permet d'ameliorer le contraste en uniformisant la distribution (maximisation de l'information/entropie) de l'intensité

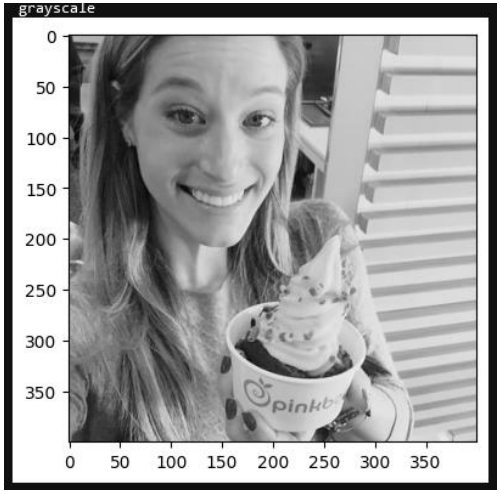

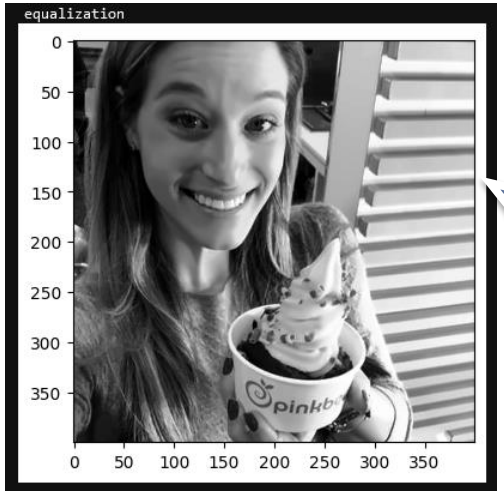

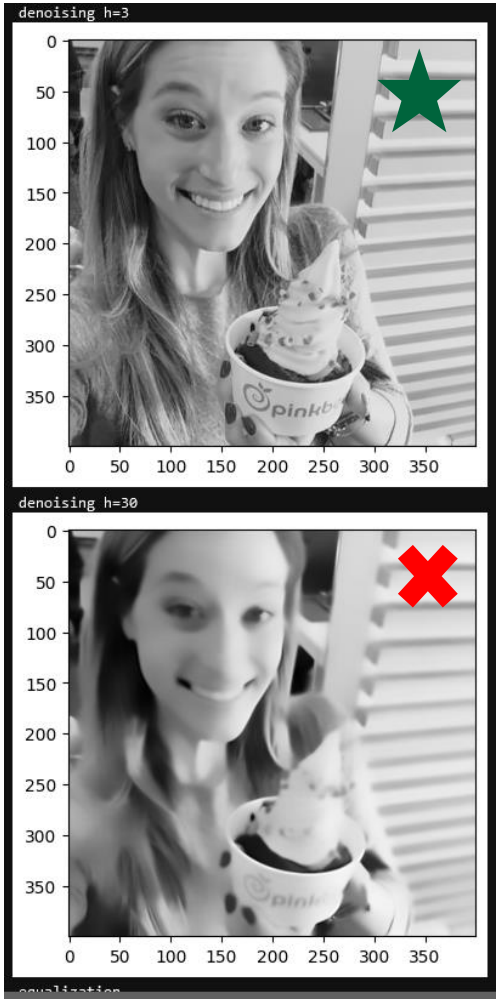

Extraction de FEATURES avec OpenCV

Detection et extraction des features avec SIFT (Scale-Invariant Feature Transform) codé sur 128 valeurs

On se limite a 500 features par photo pour ne pas exploser les compteurs

Detection des features avec STAR et extraction des features avec BRIEF codé sur 64 valeurs

6 à 10 fois plus rapide que SIFT

Detection et extraction des features avec ORB codé sur 32 valeurs (alternative gratuite à SIFT et SURF developpé par opencv)

On se limite a 500 features par photo

6 à 10 fois plus rapide que SIFT

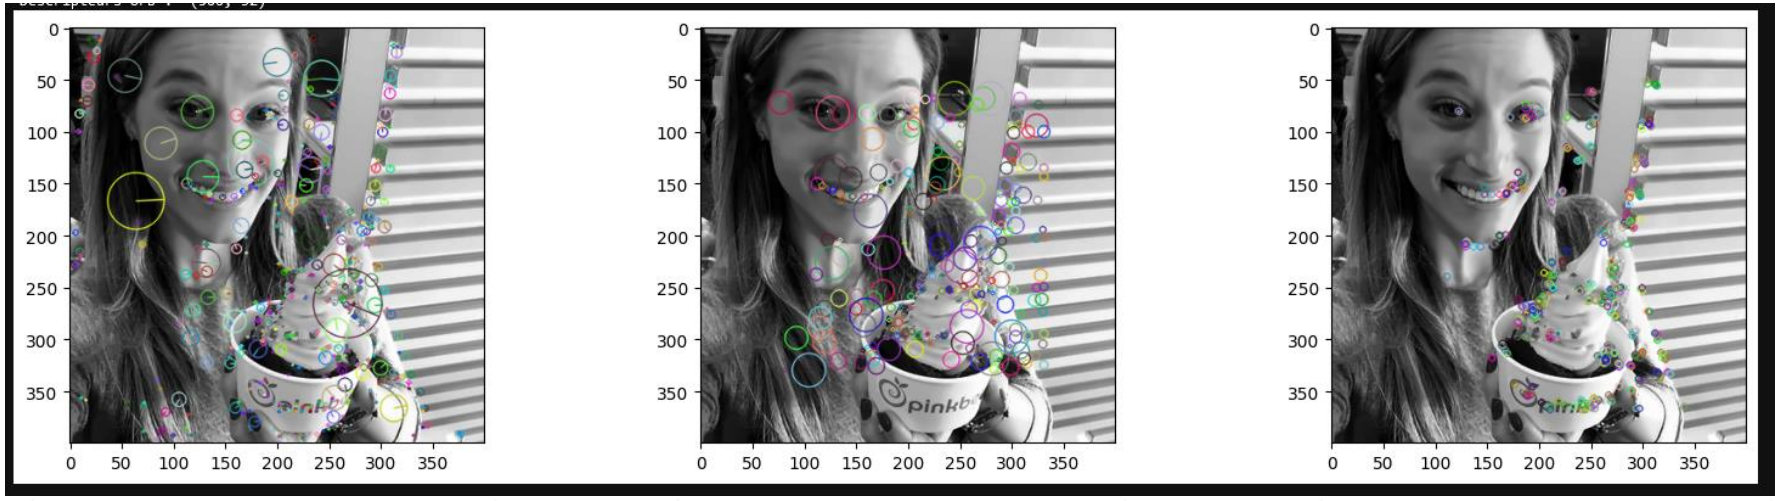

https://docs.opencv.org/3.4/da/df5/tutorial_py_sift_intro.html

https://docs.opencv.org/3.4/dc/d7d/tutorial_py_brief.html

https://docs.opencv.org/3.4/d1/d89/tutorial_py_orb.html

Traitement de 1000 photos avec OpenCV

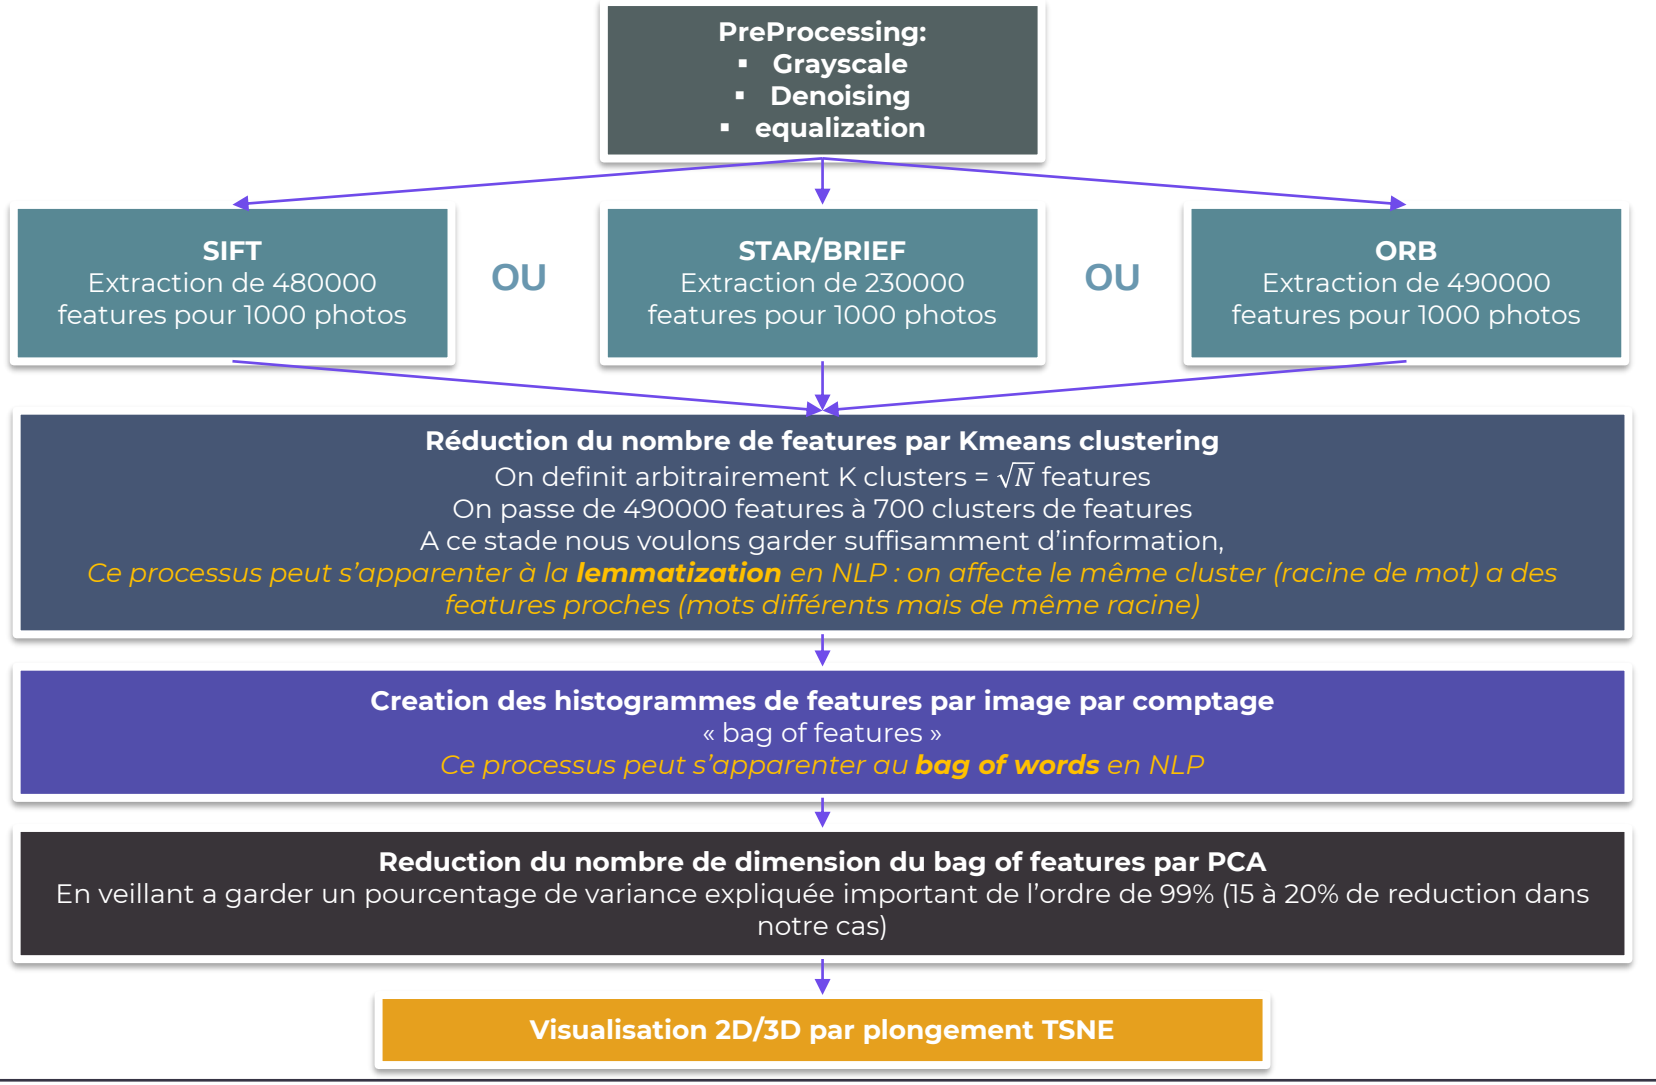

IMAGES: labels initiaux vs TSNE kmeans clustering (K=N labels initiaux)

Visuellement les menus sont assez bien clusterisés,

les métriques ARI de comparaison de clustering (label vs features) ne sont pas fantastiques *(pour rappel 1 = matching parfait, 0 = aleatoire)*

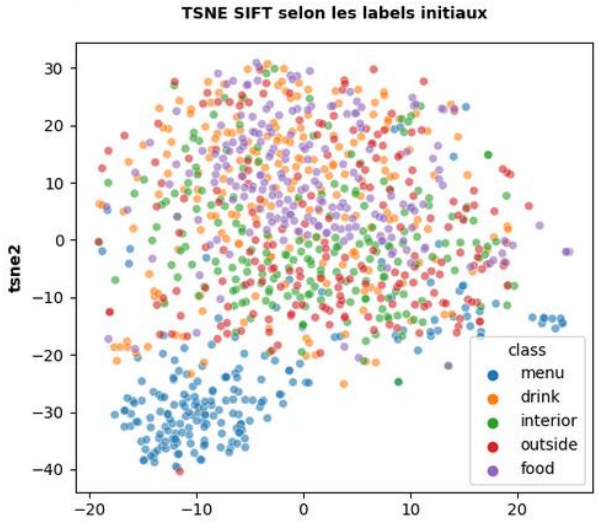

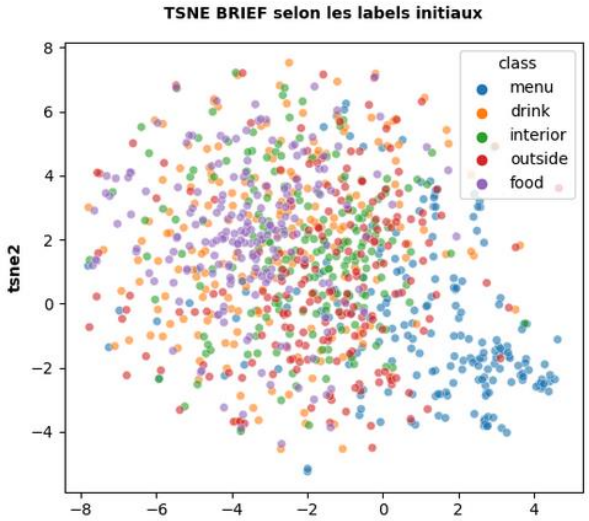

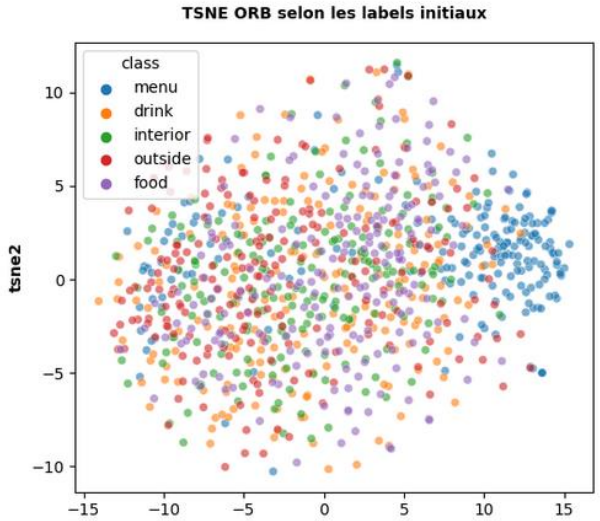

ARI=0,17

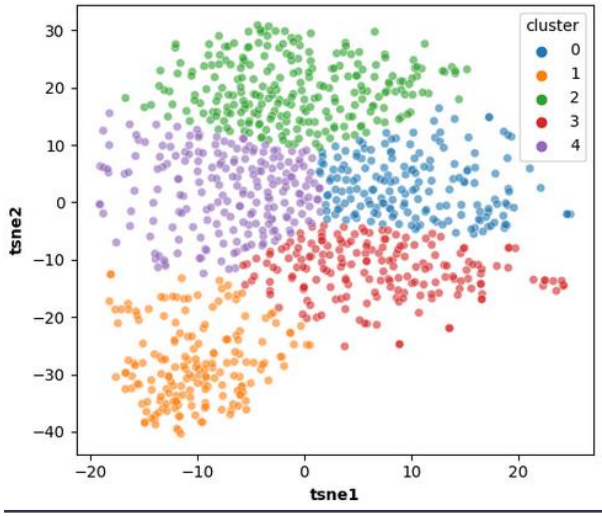

ARI=0,13

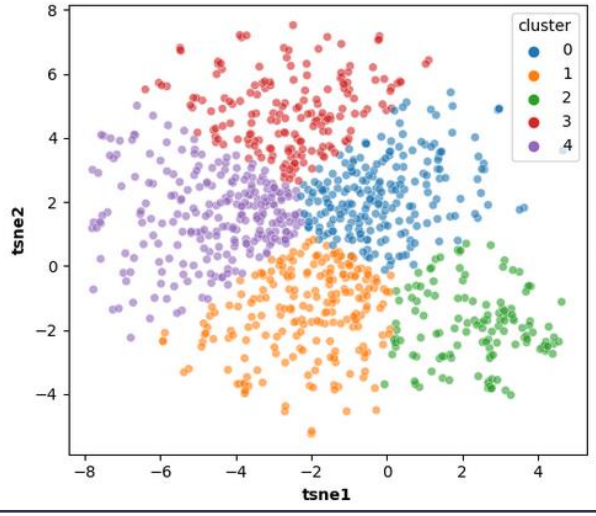

ARI=0,11

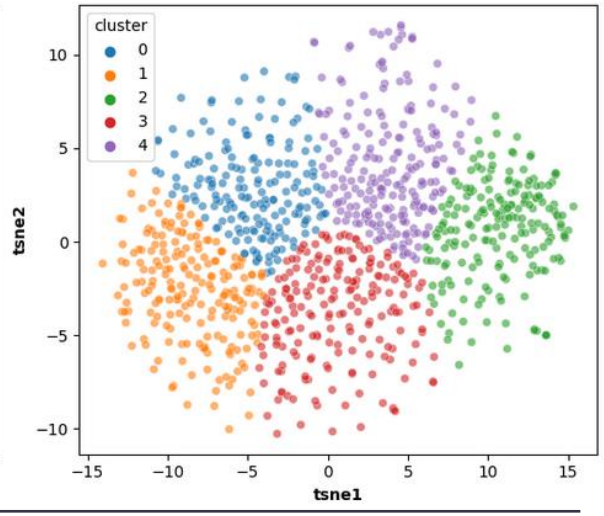

IMAGES: labels initiaux vs TSNE kmeans clustering (K=N labels initiaux)

Accuracy (entre 37 et 43% des photos sont correctement classées)
et matrice de confusion (les menus s'en sortent mieux que les autres catégories)

sift

	precision	recall	f1-score	support
0	0.32	0.28	0.30	200
1	0.84	0.76	0.79	200
2	0.36	0.45	0.40	200
3	0.33	0.31	0.32	200
4	0.31	0.33	0.32	200
accuracy			0.42	1000
macro avg	0.43	0.42	0.43	1000
weighted avg	0.43	0.42	0.43	1000

brief

	precision	recall	f1-score	support
0	0.33	0.36	0.34	200
1	0.34	0.38	0.36	200
2	0.86	0.56	0.68	200
3	0.32	0.28	0.30	200
4	0.45	0.56	0.50	200
accuracy			0.43	1000
macro avg	0.46	0.43	0.44	1000
weighted avg	0.46	0.43	0.44	1000

orb

	precision	recall	f1-score	support
0	0.33	0.30	0.31	200
1	0.21	0.21	0.21	200
2	0.69	0.68	0.68	200
3	0.29	0.29	0.29	200
4	0.35	0.38	0.36	200
accuracy			0.37	1000
macro avg	0.37	0.37	0.37	1000
weighted avg	0.37	0.37	0.37	1000

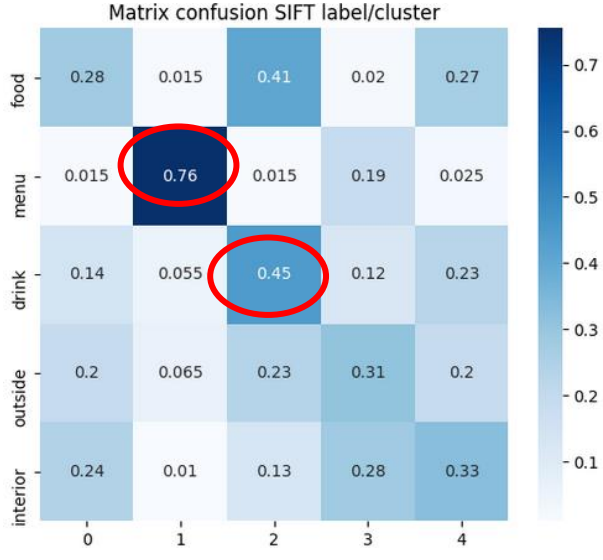

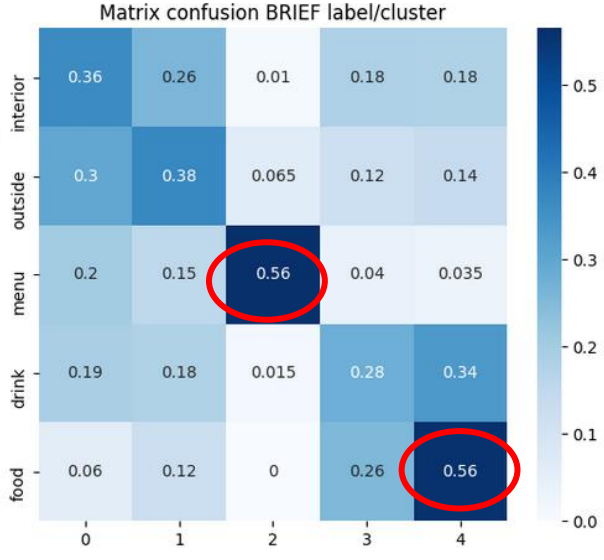

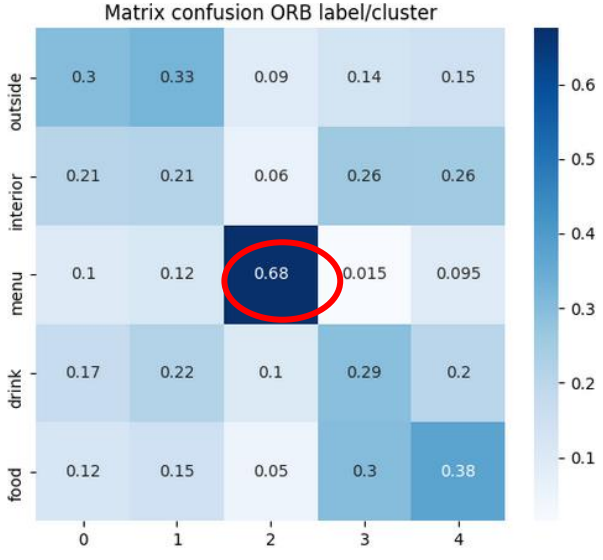

Voyons si les reseaux de neurones peuvent faire mieux: VGG16

- **En matière de reconnaissance d'images, quelques réseaux ont fait leur preuve au cours des 10 dernières années, grâce notamment au challenge imagenet** « ILSVRVC »
  - 2014 – VGG16 : 92,7% au top 5 test accuracy d'imagenet
  - 2014 – GoogleNet: 93,3% au top 5 test accuracy d'imagenet
  - 2015 – ResNet
  - 2015 – Inception V3

- **Pour nos besoins nous avons choisi de nous concentrer sur le reseau VGG16 qui est populaire:**
  - C'est un réseau de 16 couches et 140 millions de paramètres
  - On peut le divisier en 2 parties:
    - Les 13 premières couches constitueées de 5 blocs de couches de convolution (filtrage)
      - Des couches supplémentaires de pooling après chaque bloc jouent le rôle de réducteur de dimension
    - Les 3 dernières qui sont les couches fully connected debouchant sur la classification
  - Il prend en entrée des images de 224x224x3
  - En sortie on recupere une matrice de N lignes/images K colonnes/proba d'appartenance à la classe K

Architecture VGG 16

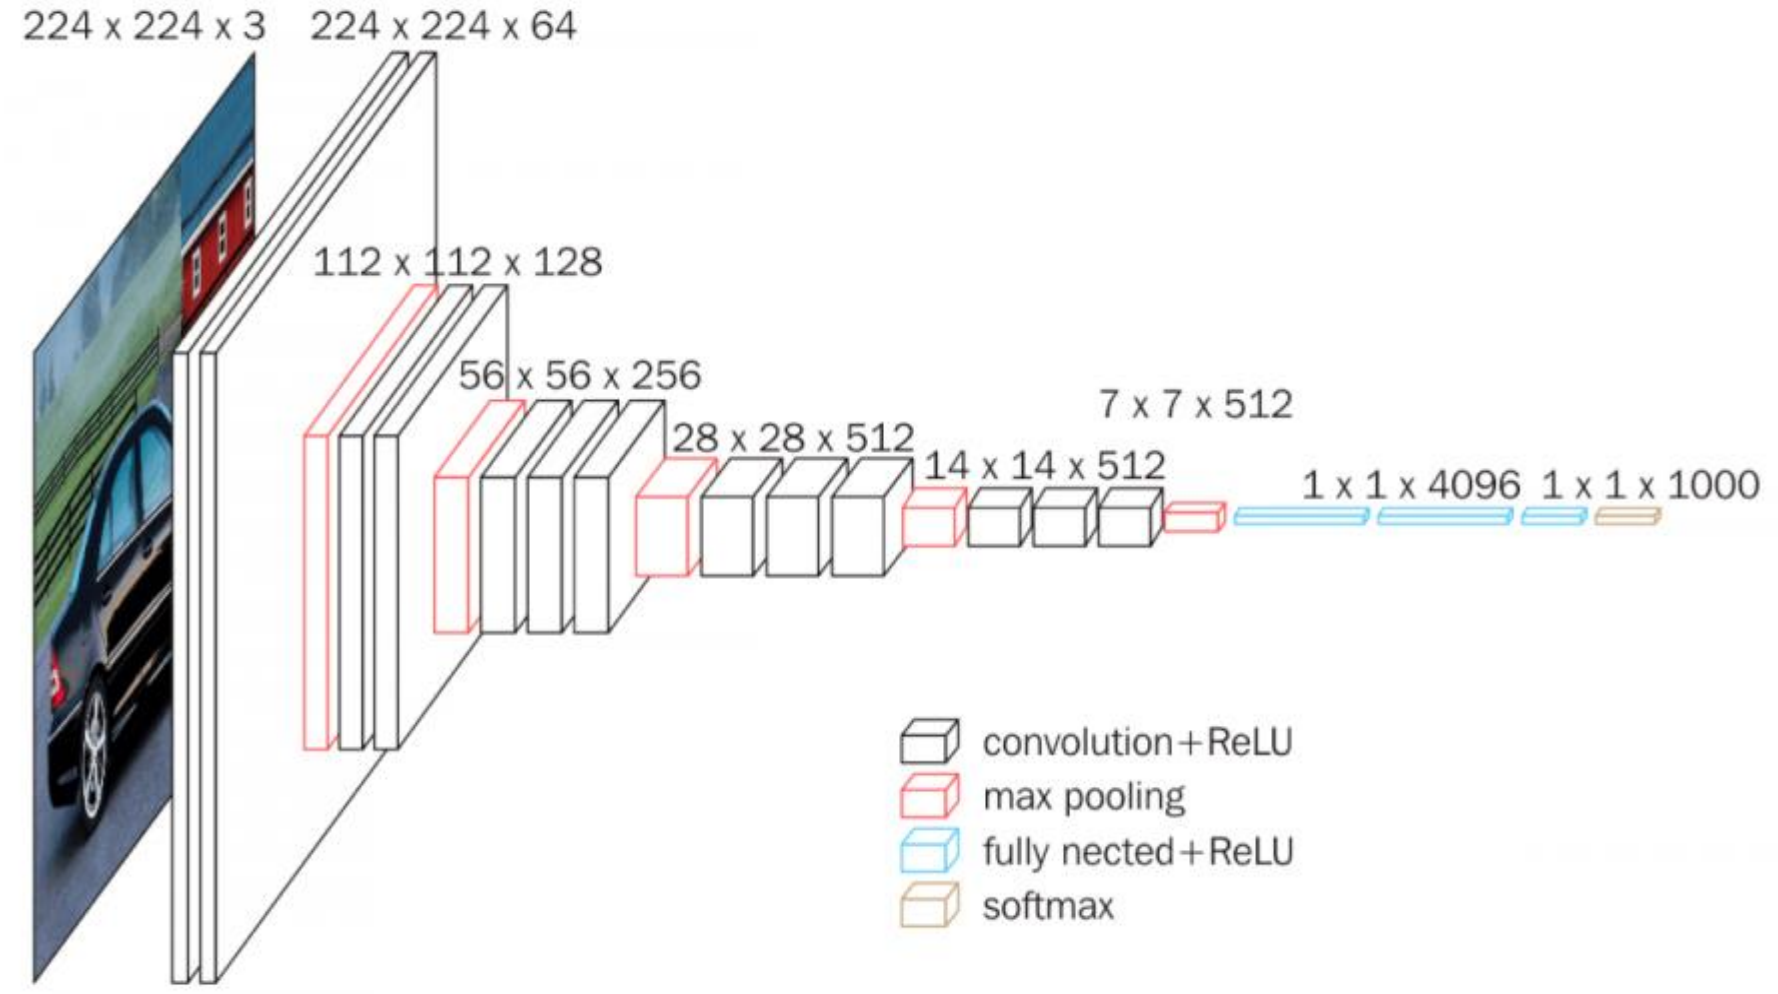

Test VGG 16 sur 1 ou 2 photos avec

TensorFlow Keras

```
Top 3 : [('n07615774', 'ice_lolly', 0.16271389), ('n04357314', 'sunscreen', 0.12443831), ('n03476991', 'hair_spray', 0.11060534)]
```

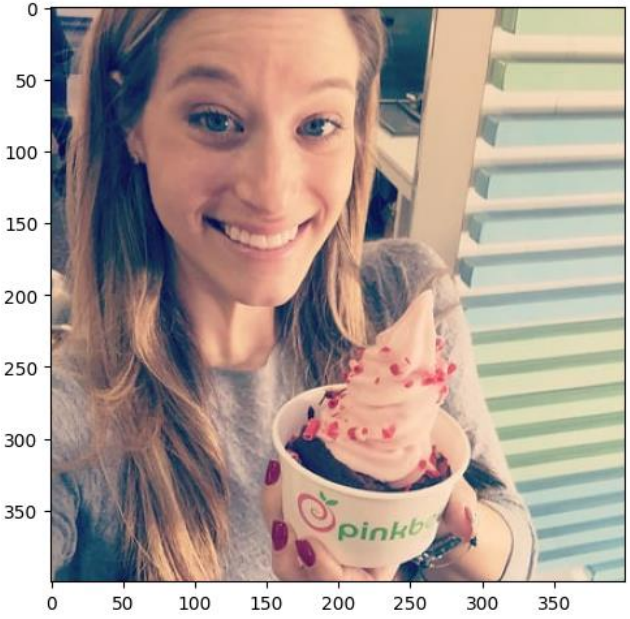

Sucette glacée à 16%
Crème solaire à 12%

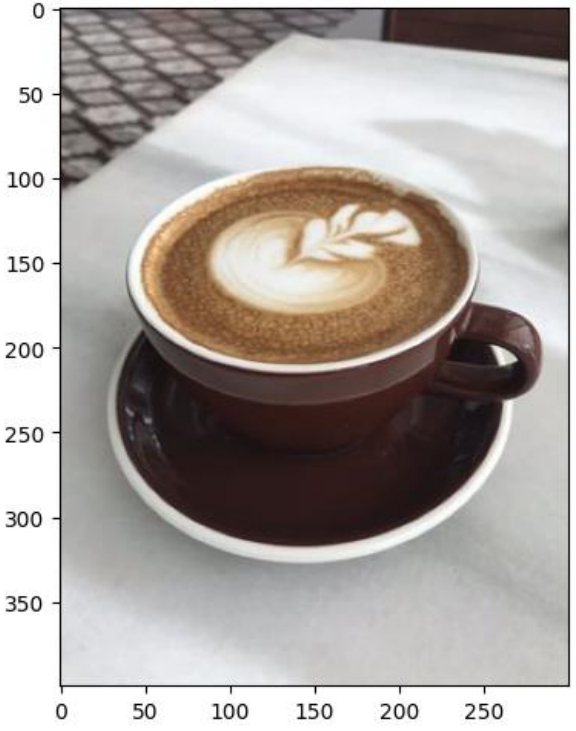

Expresso à 20%
Palet à 15% (soucoupe peut etre)

```
Top 3 : [('n07920052', 'espresso', 0.20633043), ('n04019541', 'puck', 0.15391573), ('n03259280', 'Dutch_oven', 0.10202522)]
```

Traitement de 1000 photos avec extraction des features de VGG16 post convolutions via TensorFlow Keras

VGG 16 PreProcessing de la collection des 1000 images

Extraction des features à la fin des blocs de convolution de VGG16:
On ajoute en sortie une couche de pooling max pour passer d'un array (1000,7,7,512) à une matrice (1000,512)

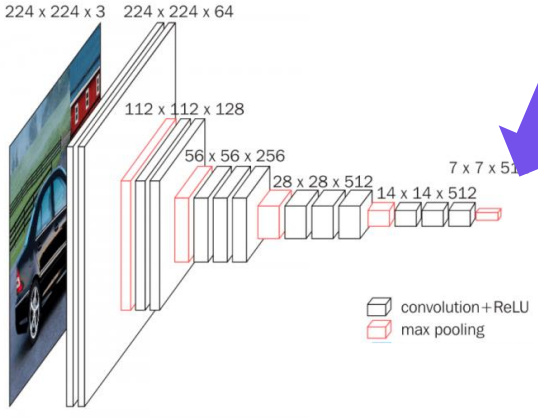

Les features sont recuperees à ce niveau la

Reduction du nombre de dimension du bag of features par PCA
En veillant a garder un pourcentage de variance expliquée important de l'ordre de 99% (17% de reduction de taille dans notre cas)

Visualisation 2D/3D par plongement TSNE

IMAGES: labels initiaux vs VGG16 features TSNE kmeans clustering (K=N labels initiaux)

Accuracy de 80%

Diagonale limpide de la matrice de confusion : de bien meilleurs résultats que le SIFT

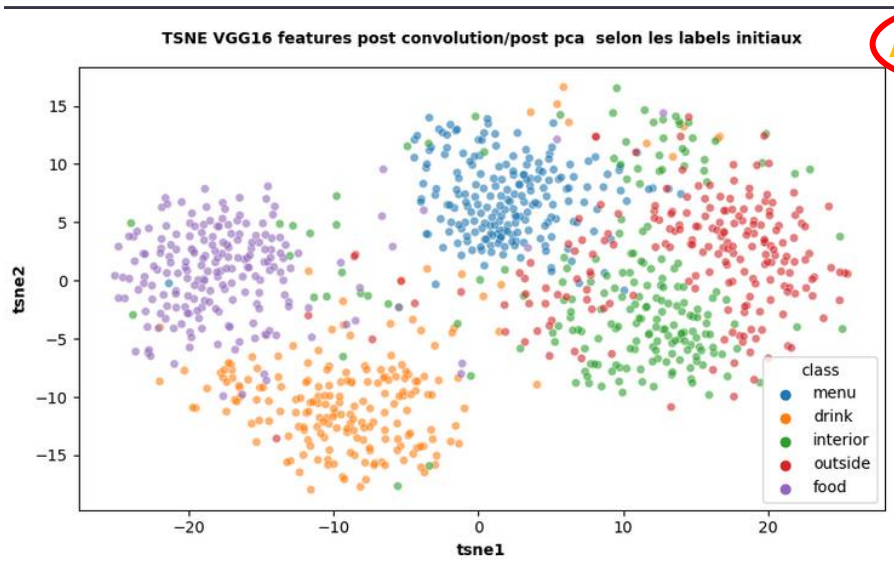

ARI=0,6

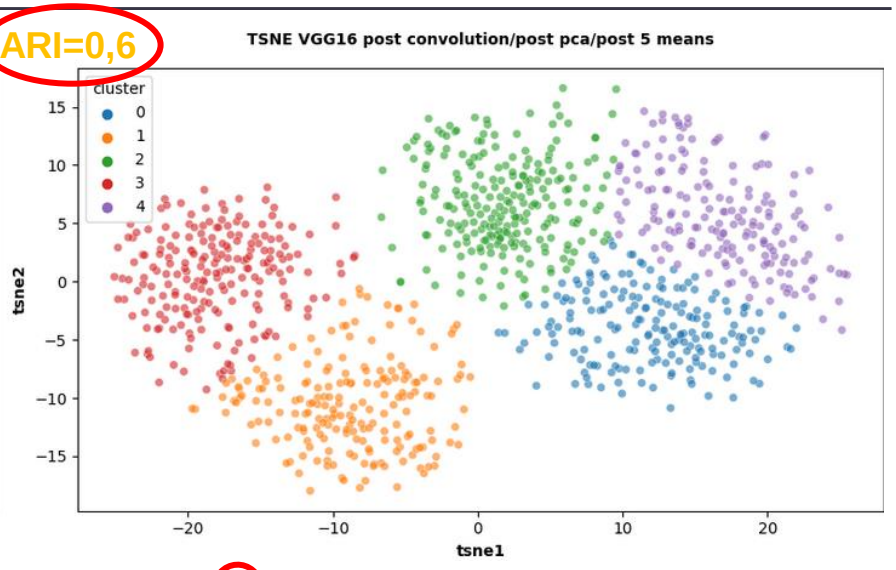

	precision	recall	f1-score	support
0	0.70	0.66	0.68	200
1	0.88	0.86	0.87	200
2	0.81	0.93	0.86	200
3	0.87	0.91	0.89	200
4	0.71	0.64	0.67	200
accuracy			0.80	1000
macro avg	0.79	0.80	0.79	1000
weighted avg	0.79	0.80	0.79	1000

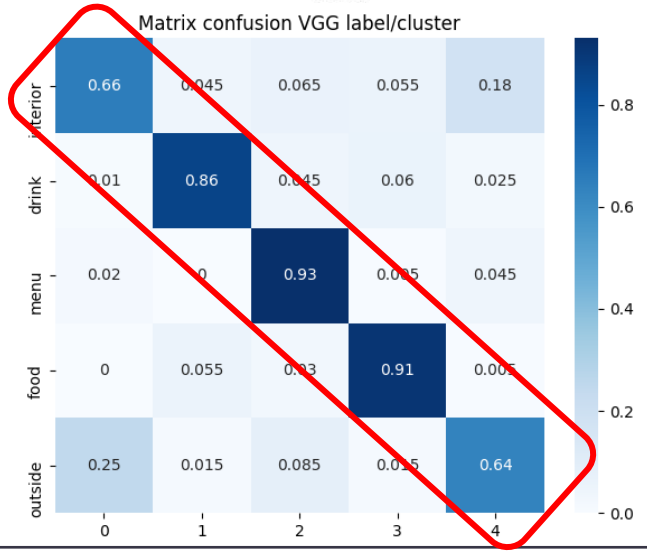

Traitement de 1000 photos avec extraction des features de VGG16 après la première couche fully connected via TensorFlow Keras

VGG 16 PreProcessing de la collection des 1000 images

Extraction des features après la première couche fully connected:
On récupère en sortie une matrice (1000,4096)

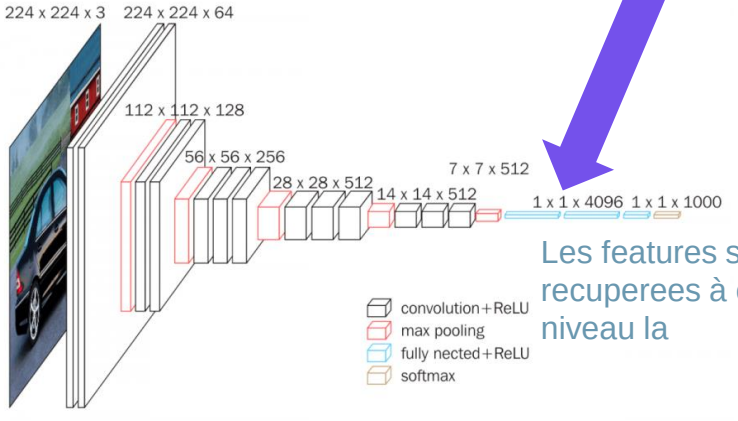

Les features sont recuperees à ce niveau la

Reduction du nombre de dimension du bag of features par PCA
En veillant a garder un pourcentage de variance expliquée important de l'ordre de 99% (79% de reduction de taille dans notre cas : il reste 830 colonnes)

Visualisation 2D/3D par plongement TSNE

IMAGES: labels initiaux vs VGG16 features TSNE kmeans clustering (K=N labels initiaux)

Accuracy de 88%

Diagonale limpide de la matrice de confusion : Très bon clustering

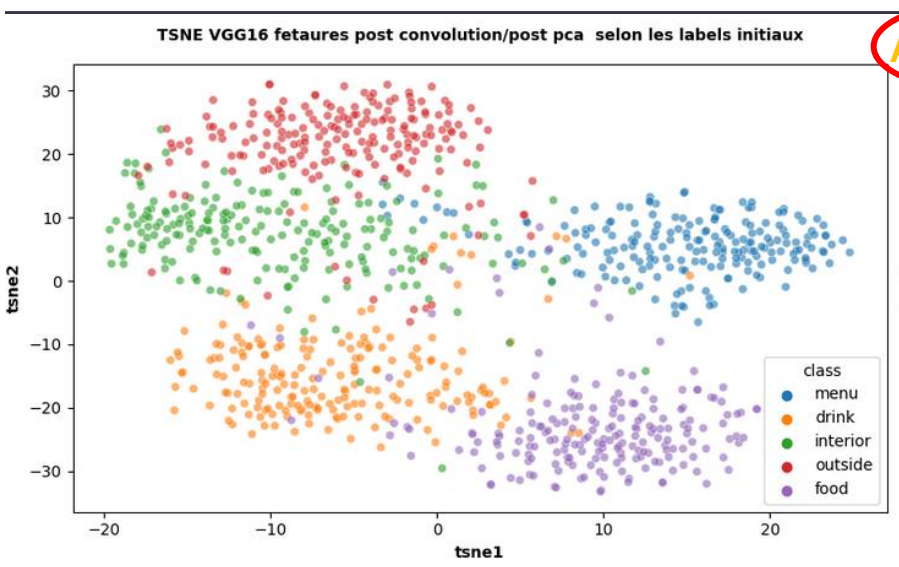

ARI=0,73

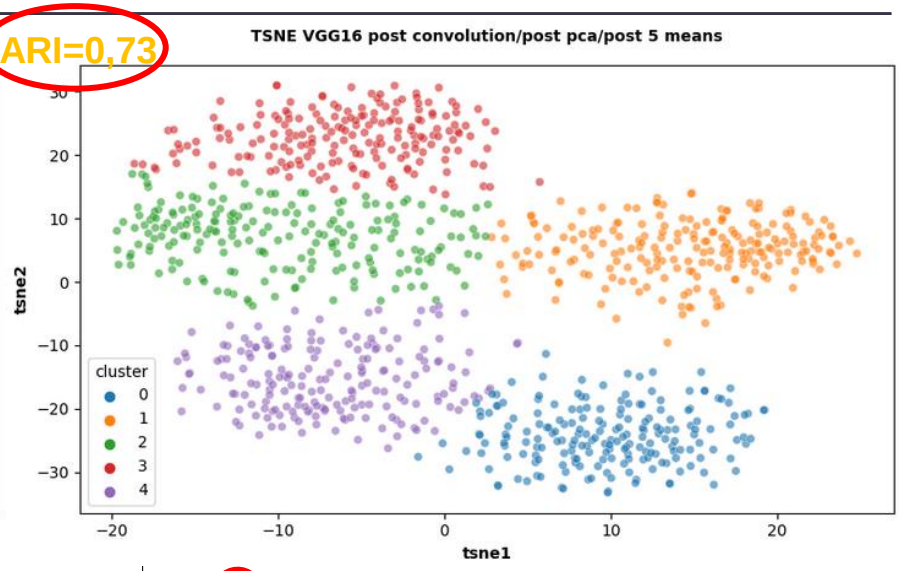

	precision	recall	f1-score	support
0	0.91	0.90	0.90	200
1	0.88	0.95	0.92	200
2	0.81	0.83	0.82	200
3	0.91	0.88	0.90	200
4	0.89	0.85	0.87	200
accuracy			0.88	1000
macro avg	0.88	0.88	0.88	1000
weighted avg	0.88	0.88	0.88	1000

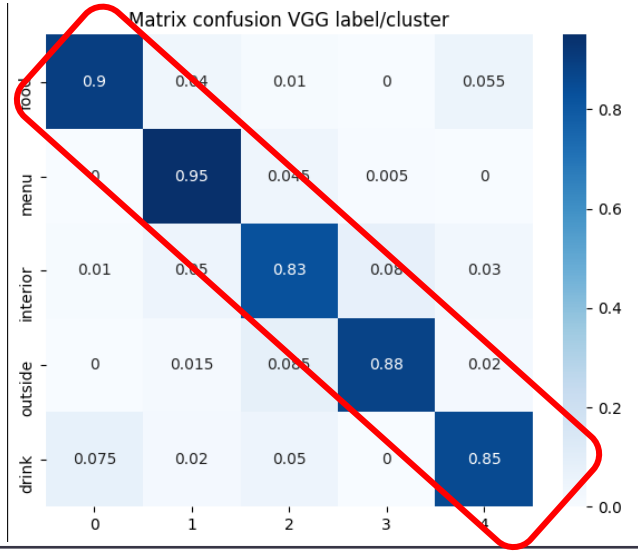

VGG 16 Transfer Learning :
couches de convolutions identiques et non entrainables
Couches de classification bespoke et entrainables

VGG 16 PreProcessing de la collection des 1000 images

Couches de convolution VGG16 non entrainables : poids imagenet

Couche flatten pour passer de 4D à 2D

Couche dense de 1024 neurones avec activation RELU

Couche dense de sortie 5 classes avec activation softmax (generalisation de la sigmoide à plusieurs classes)

Compilation du VGG bespoke: 40 millions de paramètres dont 25 millions entrainables

Entrainement des couches entrainables sur 1000 photos du jeu d'entrainement avec validation split de 0,2 et 50 epochs

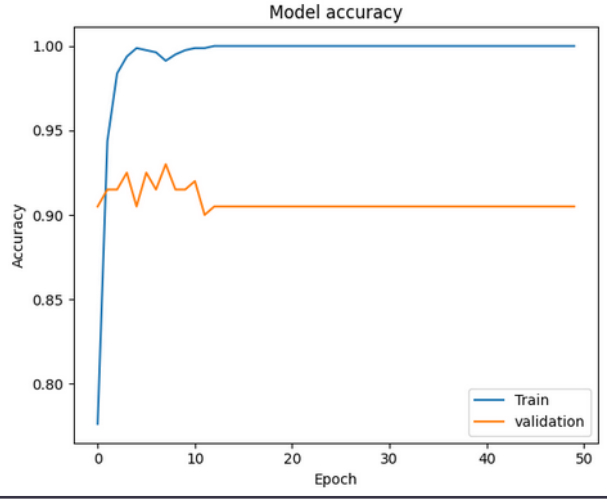

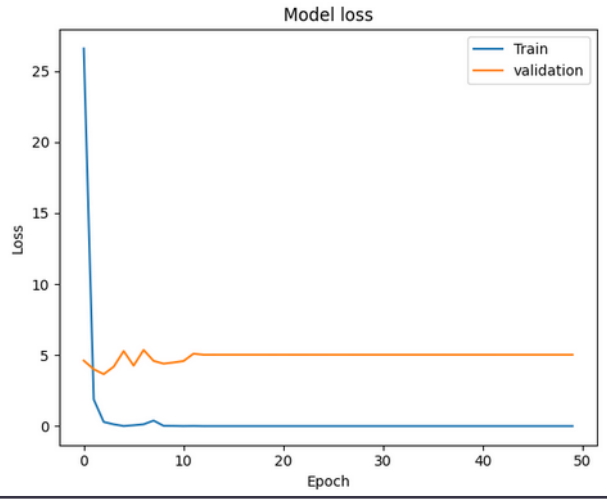

La Prédiction sur 1000 photos du jeu de test Donnera un ARI de 0,79 avec les vrais labels

D

PROJET API: COLLECTER UN ECHANTILLON DE DONNEES DE 200 RESTAURANTS VIA L'API YELP

API YELP
2 possibilités plus ou moins flexibles mais limitées

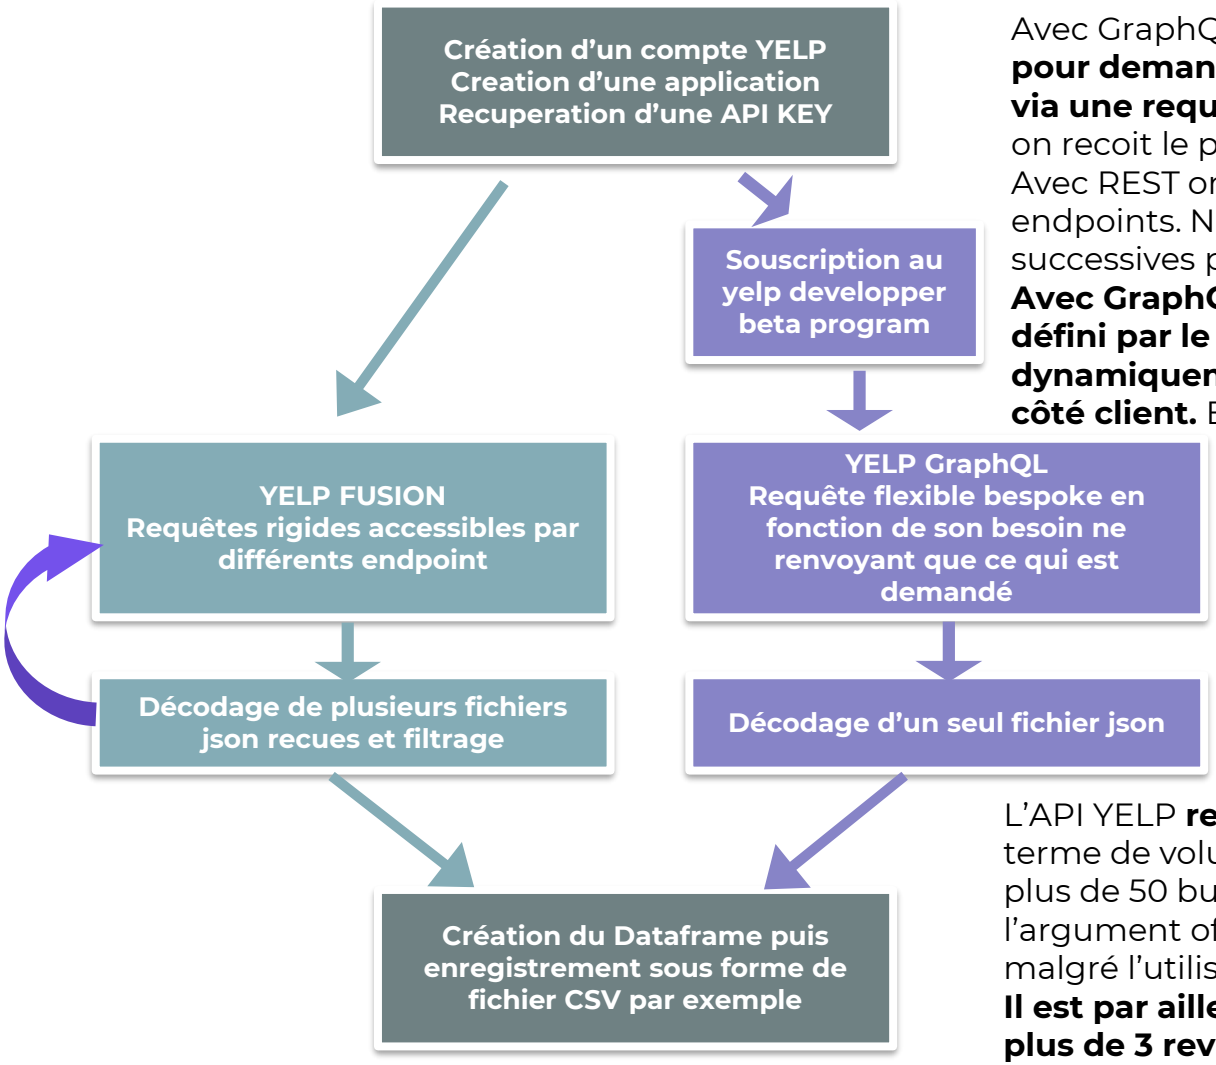

Avec GraphQL, Un **seul POST est nécéssaire pour demander exactement ce que l'on veut via une requête GraphQL.** Le serveur gère, et on recoit le payload complet.
Avec REST on recevait des objets définis par des endpoints. Necessité de faire plusieurs requetés successives pour récupérer son besoin
Avec GraphQL, on n'adapte pas un objet défini par le backend, mais on definit dynamiquement l'objet que l'on va recevoir côté client. Et ça, ça change tout

L'API YELP **reste relativement limitée** en terme de volume de donnée : Pour récupérer plus de 50 business , nous devons ruser avec l'argument offset en lançant plusieurs requêtes malgré l'utilisation de GraphQL,
Il est par ailleurs impossible de récupérer plus de 3 reviews par restaurant

Partie data de la requête GraphQL

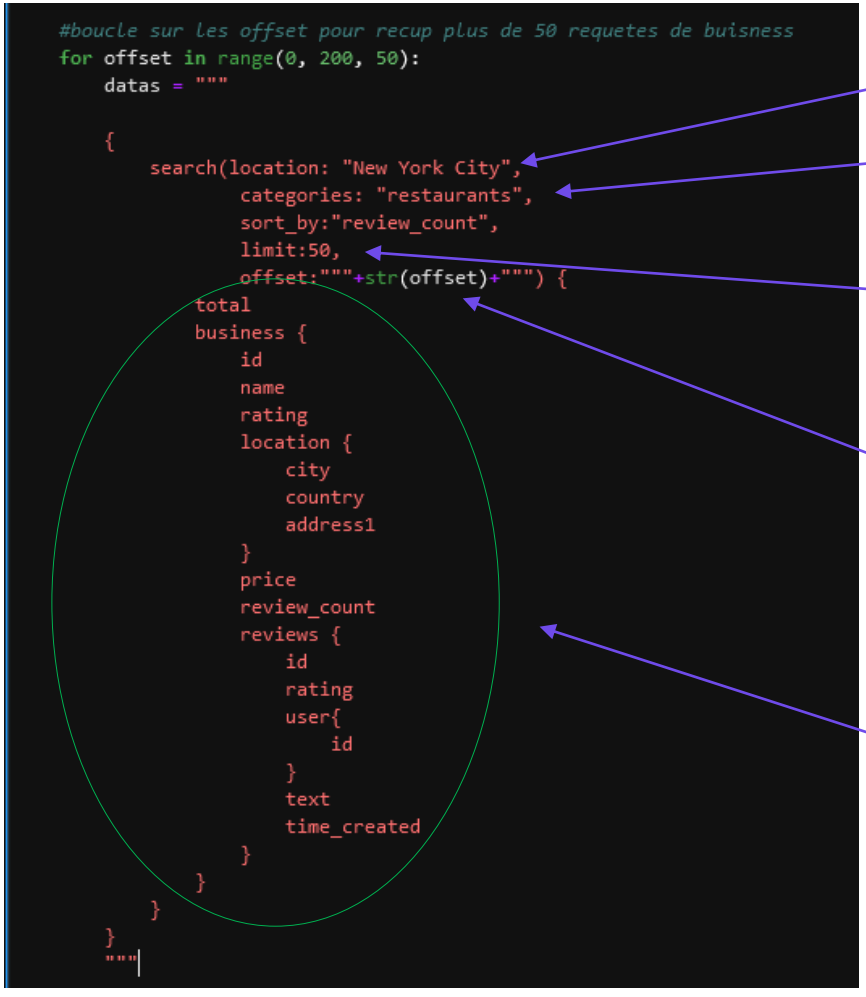

```
#boucle sur les offset pour recup plus de 50 requetes de buisness
for offset in range(0, 200, 50):
    datas = """

    {
        search(location: "New York City",
                categories: "restaurants",
                sort_by:"review_count",
                limit:50,
                offset:"""+str(offset)+""") {
            total
            business {
                id
                name
                rating
                location {
                    city
                    country
                    address1
                }
                price
                review_count
                reviews {
                    id
                    rating
                    user{
                        id
                    }
                    text
                    time_created
                }
            }
        }
    }
    """
```

Filtre sur la ville de New York

Filtre sur la catégorie « restaurant »

Limite de résultat à 50 business par requete mais on ne peut pas aller au dela

Utilisation de la variable offset afin de recuperer 200 business differents avec 4 requetes successives de 50 resultats

Données que l'on souhaite recuperer, sur mesure , par rapport à notre besoin